Gold — desenho

Como medir o efeito da chuva na velocidade dos ônibus, trecho a trecho

Projeto Ônibus SP × Chuva · Gabriel Graciano Dias
25/10/2026

Para que serve a gold

A silver tem as duas metades do problema, separadas: **velocidade por trecho entre paradas a cada 10 min** (`silver.velocidade_trecho`) e **chuva por posto a cada 10 min** (`silver.chuva_10min`). A gold junta as duas e responde aos KRs:

KR	Pergunta	Saída da gold
KR1	Quanto a velocidade cai durante a chuva, por trecho?	efeito por intensidade de chuva (cidade, período do dia, trecho)
KR2	Quanto tempo leva para a velocidade voltar ao normal?	curva de recuperação depois do fim da chuva
KR3	Quais os 10 trechos mais afetados, com ranking estável?	efeito por trecho com incerteza, ajustado por quantidade de dado, e frequência no top-10
KR4	A queda está associada a tipo de via e histórico de alagamento?	efeito por trecho × atributos de infraestrutura
KR5 (aspiracional)	Dá para prever a queda na próxima hora?	modelo preditivo com validação temporal

Este documento registra **o que os dados mostraram numa primeira exploração** (25/10) e **as decisões de desenho que saem disso**. As consultas estão em `analises/gold_exploracao/`.

1. O que os dados mostraram

Todas as contas desta seção: **dia útil, 6h–22h, 25/08 a 24/10**; chuva do **posto DAEE confiável mais próximo** do trecho (70 postos).

1.1 Quanto dado cada trecho tem

- **28.970 trechos físicos** (par de paradas consecutivas, juntando todas as linhas que passam ali) têm velocidade em dia útil. Metade é servida por uma linha só; 10% por 7 ou mais.
- Na mediana, um trecho tem velocidade em **75% das janelas de 10 min**; 21.883 têm em pelo menos metade.
- **Mas cada janela tem, na mediana, só 2 passagens de ônibus.** Uma velocidade de 10 min sozinha é ruidosa: o efeito precisa ser estimado agregando muitas janelas.

1.2 Distância até um posto confiável

	Mediana	90% dos trechos	98% dos trechos
posto confiável mais próximo (qualquer rede)	**1,6 km**	até 3,4 km	até 5 km

85% dos trechos têm um posto confiável a até 3 km.

1.3 A chuva é parecida a que distância?

Correlação entre pares de postos DAEE:

Distância	a 10 min	a 1 h
até 2 km	**0,89**	0,94
3–5 km	0,72	0,88
5–8 km	0,61	0,83
8–12 km	0,52	0,77
20–30 km	0,32	0,64

O posto mais próximo (1,6 km na mediana) representa bem a chuva do trecho; acima de ~5 km a representação piora rápido. Ressalva: set/out de 2026 tiveram chuva **frontal** (espalhada). No verão, chuva convectiva é mais localizada e a correlação cai mais rápido com a distância.

A rede CEMADEN piora a correlação a 10 min, e por um motivo que importa: quando seca, ela manda uma leitura por hora; quando volta a chover, a primeira leitura cobre a hora inteira e o rateio da silver **espalha a chuva até 50 min antes de ela começar**. Para medir início e fim de chuva (KR2), isso é um problema.

Falta de dado nos postos não tem relação com chuva: a chuva média na cidade é a mesma quando o posto está com ou sem dado (0,337 vs 0,336 mm/h). Não há o viés “o posto cai durante o temporal”.

1.4 Primeira estimativa do efeito (KR1)

Velocidade relativa à **velocidade normal do mesmo trecho e hora em período seco** (3 h sem chuva no posto), por intensidade da chuva nos últimos 30 min. Razão = Σ distância ÷ Σ(tempo × velocidade normal), ou seja, ponderada pelo tempo que os ônibus passaram no trecho.

Chuva nos últimos 30 min	Pico manhã (6–9h)	Fora do pico	Pico tarde (16–19h)	Janelas
seco (3 h sem chuva)	1,000	1,000	1,000	61,0 M
pós-chuva (choveu nas 3 h, não nos 30 min)	0,978	1,000	0,992	9,6 M
fraca (< 2,5 mm/h)	0,962	0,971	0,944	6,5 M
moderada (2,5–10 mm/h)	0,939	0,960	**0,900**	1,9 M
forte (10–25 mm/h)	0,918	0,923	**0,885**	288 mil
muito forte (≥ 25 mm/h)	—	0,880	**0,819**	53 mil

Relação dose-resposta clara: de −3% a −6% com chuva fraca até **−18% com chuva muito forte no pico da tarde**. O pico da tarde é o mais sensível.

1.5 Recuperação depois da chuva (KR2)

Mesma razão, para janelas sem chuva nos últimos 30 min, pelo tempo desde a última chuva no posto:

Minutos desde o fim	Fraca	Moderada	Forte (pico ≥ 10 mm/h)
20	0,983	0,972	0,970
40	0,982	0,974	0,976
60	0,987	0,984	0,984
80	0,990	0,992	0,993
100–120	~1,00	~1,00	~1,00

A velocidade volta ao normal ~1h30–2h depois do fim da chuva, inclusive depois de chuva forte. Linha de base com 3 h ou com 6 h sem chuva dá o mesmo resultado (0,971 vs 0,970 aos 20 min): **3 h sem chuva é uma linha de base segura.**

1.6 Efeito por trecho (KR3)

Para chuva moderada ou mais (≥ 2,5 mm/h nos últimos 30 min):

- cada trecho tem, na mediana, **78 janelas de chuva — mas em só ~12 dias de chuva**. Janelas do mesmo dia não são independentes: **a evidência efetiva de cada trecho é de ~12 dias**;
- efeito mediano **−3,3%** (razão 0,967); os 10% mais afetados perdem 15% ou mais; 10% ficam até 4% *mais rápidos* (ruído e efeitos reais);

- a dispersão entre trechos cai com mais dado (desvio 0,115 com 20–50 janelas → 0,084 com ≥ 100) mas não some: **parte é ruído, parte é diferença real**. Separar as duas é o problema do KR3.

1.7 A linha de base muda com o dia da semana e com o tempo

Velocidade em período seco, relativa à linha de base trecho × hora:

	Seg	Ter	Qua	Qui	Sex
até 20/09 (coleta a 2 min)	1,032	1,006	0,987	0,984	0,967
desde 21/09 (coleta a 1 min)	1,039	1,014	0,998	1,000	0,997

- **Segunda ~3–4% mais rápida, sexta mais lenta.** Sem ajuste, uma chuva numa segunda parece menor e numa sexta, maior.
- O período desde 21/09 fica ~1% acima. Pode ser real (mudança de calendário, de demanda) ou da mudança de cadência da coleta; não dá para separar com estes dados. Por semana, a velocidade seca varia de 0,985 a 1,015.

1.8 Dois testes de validade

Antecipação (leads): antes de a chuva começar, a velocidade deveria estar normal. Janelas secas (3 h sem chuva no posto), pelo tempo até o posto registrar chuva:

Minutos até a chuva no posto	0–20	20–40	40–60	≥ 60
Razão	0,982	0,993	0,998	~1,000

- **Confirma o fuso**: com 3 h de desalinhamento, a queda apareceria horas antes, não 20–40 min.
- O resíduo (−1,8% nos 20 min anteriores) é o esperado com o posto a ~1,6 km: a chuva chega ao trecho antes do posto, ou começa como garoa abaixo da resolução do pluviômetro (0,2 mm). Consequência: a chuva do posto **mede o efeito com erro**, o que o puxa para zero — os efeitos estimados são, se tanto, **limites inferiores** (ver 2.9).
- Alinhamento dos relógios conferido: na silver, a leitura das 14:50 (que acumula 14:40–14:50) vai para o slot que **começa** às 14:40, a mesma convenção da janela de velocidade.

Contaminação da linha de base pela chuva em outra região: janelas com o posto do trecho seco, pela fração dos postos DAEE da cidade chovendo no mesmo slot:

Resto da cidade	Fora do pico	Pico manhã	Pico tarde	% das janelas secas
tudo seco	1,000	1,000	1,001	87,4%
até 25% dos postos chovendo	1,003	0,999	0,997	11,9%
25% ou mais chovendo	**0,961**	1,031	**0,973**	0,7%

Há transbordamento (o congestionamento se espalha para onde não chove), mas em 0,7% das janelas secas: quase não mexe na linha de base. Mesmo assim, a definição de “seco” passa a exigir a cidade predominantemente seca (2.4).

Ônibus somem durante a chuva? Fração dos trechos de cada posto com dado na janela, relativa à fração normal (seca) no mesmo horário:

Chuva	fraca	moderada	forte	muito forte
trechos com dado (vs. seco)	0,988	0,982	0,978	**0,961**

Há um **dado faltante informativo pequeno**: com chuva muito forte, 4% menos trechos têm dado. Os piores momentos somem um pouco da amostra, então o efeito fica levemente **subestimado** — mais uma razão para ler os efeitos como limites inferiores e para analisar o número de passagens como desfecho (2.9).

1.9 Comparação com a literatura

Revisão completa em `docs/gold_literatura.md`. Poucos estudos de ônibus com AVL publicam efeito em %; a maior parte é de tráfego geral.

Fonte	Leve	Moderada	Forte	Observação
Tsapakis et al. 2013 (Londres, carros, ANPR)	+0,1–2,1% tempo	+1,5–3,8%	+4,0–6,0%	links longos da periferia sofrem mais
Zhang et al. 2018 (Pequim, floating car)	−3 a −5%	—	−12 a −15% no pico	tráfego levemente congestionado é o mais sensível
Lam et al. 2013 (Hong Kong)	−4,2%	−6,3%	−7,3%	via fonte secundária
Chaves Maia (Rio, ônibus GPS, 33 pluviômetros)	—	−1,0% (Atenção)	−7,3% (Crise)	efeito local até ~42%; BRT atenua; versões do estudo divergem
Geotab 2026 (SP, telemetria, não revisado)	−3,2% dias chuvosos	—	até −14,8%	mesmo segmento, hora e dia da semana
Este projeto (SP, ônibus, 70 postos a 10 min)	**−3 a −6%**	**−4 a −10%**	**−8 a −12%** (muito forte: até −18%)	pico da tarde o mais sensível

Nossos números estão na faixa da literatura, um pouco acima — esperado para ônibus, que somam ao tráfego o embarque mais lento com chuva (Novales et al. 2021). Heterogeneidade esperada pela literatura, e que vira hipótese do KR4: vias de maior hierarquia/mais rápidas perdem mais em %; faixa exclusiva e BRT atenuam; trechos alagáveis podem perder 20–40% e demorar mais a recuperar (Li et al. 2021, Shenzhen).

2. Decisões de desenho

2.1 Grão: trecho físico × janela de 10 min

Trecho físico = `(parada_de, parada_ate)`, juntando as linhas. Multiplica as observações onde mais importa (trechos com muitas linhas são os corredores) e é a unidade natural para o KR4 (atributos da via). Análises por linha ficam como detalhamento.

Dia útil é a análise principal; sábado e domingo à parte (outro padrão de demanda, menos dado).

2.2 Chuva de cada trecho

- **Posto(s):** média ponderada pelo inverso do quadrado da distância (IDW) dos até **3 postos confiáveis DAEE a até 5 km**; se não houver DAEE a 5 km, o mais próximo de qualquer rede confiável a até 5 km; acima disso, sem chuva atribuída. Guardar `dist_km` e `n_postos`.
- Por quê: o mais próximo já representa bem (r ≈ 0,85), a média de 3 reduz o ruído de um posto só, e o corte de 5 km vem da curva de correlação.
- **CEMADEN fora das variáveis de tempo** (início/fim de chuva) enquanto o rateio da leitura horária não for resolvido; ela entra só como reserva onde não há DAEE.
- Se um posto está sem dado naquele slot, a média usa os outros (não há viés de falta durante temporal).

Variáveis por trecho × janela: chuva no próprio slot, intensidade nos últimos 30 e 60 min (mm/h), acumulado de 3 h, minutos desde o fim da última chuva, intensidade de pico do evento.

2.3 Eventos de chuva

Por posto (e herdado pelo trecho): **início** = slot com ≥ 0,2 mm depois de ≥ 60 min secos; **fim** = último slot com chuva antes de ≥ 60 min secos. Guardar início, fim, duração, total e pico (mm/h em 30 min). 0,2 mm é a resolução do pluviômetro de báscula.

2.4 Linha de base (“velocidade normal”)

`v_base(trecho, hora) × ajuste(dia da semana, hora) × ajuste(semana)`:

- **parte do trecho:** Σd/Σt nas janelas **secas estritas** do trecho naquela hora;
- **seco estrito:** nenhuma chuva (≥ 0,2 mm) nos postos do trecho nas **3 h anteriores** (a recuperação leva ~2 h; 3 h e 6 h dão o mesmo resultado) **e** menos de 25% dos postos da cidade chovendo no slot (transbordamento, seção 1.8);
- **ajustes multiplicativos estimados para a cidade** (ou por região) nas janelas secas: dia da semana × hora e semana (segunda +3–4%, sexta mais lenta; semanas de 0,985 a 1,015);
- mínimo de janelas secas por trecho × hora (calibrar; partida: 30).

Separar assim evita estimar trecho × hora × dia da semana × semana direto (célula com pouquíssimo dado). Sensibilidade: só o período a 1 min (21/09–24/10).

2.5 KR1 — efeito da chuva

1. **Descritivo** (como na 1.4): razão por classe de intensidade × período do dia, com intervalo de confiança por **bootstrap por blocos de dia** (janelas do mesmo dia são dependentes; o tamanho efetivo da amostra é o número de dias/eventos, não o de janelas).
2. **Modelo:** log da velocidade da janela ~ efeitos fixos (trecho × hora, dia da semana × hora, semana) + chuva + pós-chuva + interação com período do dia; pesos = tempo dos ônibus na janela. Em duas versões (recomendação da literatura):
    - **(A) efeito total** — sem efeito fixo de data × hora: inclui o transbordamento para a rede;
    - **(B) efeito local** — com efeito fixo de data × hora por macrozona: identifica só pela diferença de chuva entre trechos na mesma hora. A diferença A − B mostra quanto do efeito é sistêmico.
3. **Chuva no modelo:** classes (leve < 2,5; moderada 2,5–10; forte 10–25; muito forte ≥ 25 mm/h) e, em paralelo, curva contínua (spline) da intensidade e defasagens de 0 a 120 min (modelo de defasagens distribuídas, DLNM), para não depender dos cortes.
4. **Inferência:** erro-padrão agrupado por **dia** (ou em duas vias, trecho e dia); com ~60 dias, **wild cluster bootstrap**.
5. **Caudas:** regressão quantílica (τ = 0,1 / 0,5 / 0,9) da anomalia — a literatura mostra efeito maior nos piores casos do que na média.

2.6 KR2 — recuperação

- **Estudo de evento:** razão em relação à linha de base para τ = −60 … +180 min em torno do **início** e do **fim** de cada evento (2.3), por intensidade do evento, período do dia e grupo de trecho. Antes do início deve dar ~1 (teste de antecipação, 1.8).
- **Tempo de recuperação** = primeiro instante depois do fim em que a razão volta para dentro da banda da linha de base (±1%, ou ±1 desvio-padrão das janelas secas do trecho) **e fica lá por ≥ 3 janelas (30 min)**; busca até 3 h depois do fim.
- **Perda acumulada** (área do "triângulo de resiliência") = Σ(1 − razão) × tempo, em minutos-ônibus perdidos.
- **Por trecho ou corredor:** análise de sobrevivência (Kaplan–Meier, Cox com atributos de infraestrutura), com **censura** quando volta a chover antes da recuperação ou acaba a operação do dia — alguns trechos alagáveis podem não se recuperar dentro do evento.
- Primeiro resultado da cidade: **~100–120 min** (seção 1.5).

2.7 KR3 — ranking dos trechos mais afetados

1. **Estágio 1 — efeito bruto por trecho:** anomalia nas janelas com chuva ≥ moderada, com erro-padrão por bootstrap/agrupamento por dia. **Regra de dado mínimo ([N] dos KRs):** chuva ≥ moderada em **≥ 8 dias** e ≥ 30 janelas, e linha de base com ≥ 30 janelas secas por hora usada; posto a até 5 km.
2. **Estágio 2 — encolhimento por Bayes empírico com covariáveis:** efeito do trecho ~ Normal($X\gamma$, τ^2) (estilo Fay–Herriot, ou *adaptive shrinkage*, pacote `ashr`). Trechos com pouco dado são puxados para o esperado pelas covariáveis; os bem medidos mantêm o próprio efeito. **O mesmo modelo responde ao KR4**: γ são os efeitos de infraestrutura.
3. **Ranking pela posterior**, não pela estimativa bruta: para cada trecho, P(estar no top-10) e o intervalo do rank.
4. **Estabilidade:** bootstrap por blocos de dia (estratificado), refazendo os dois estágios; frequência no top-10/top-20 e índice de Jaccard entre os top-10 das réplicas. Se os efeitos do topo forem muito

próximos, usar bootstrap m-de-n.
5. **Multiplicidade:** ~29 mil trechos → controlar a taxa de falsas descobertas (Benjamini–Hochberg) ou *local false sign rate* do `ashr` ao dizer quais trechos têm efeito.
6. **Critério de "estável" definido antes de olhar** (a confirmar com o Rafael): o top-10 reportado aparece no top-20 em ≥ 80% das réplicas; Jaccard mediano ≥ 0,5.
7. Alternativa de unidade, se o ranking por trecho for instável: **corredores** (sequências de trechos consecutivos de 0,5–1 km).

2.8 KR4 — infraestrutura

Fontes levantadas e testadas a partir deste PC (detalhes, URLs e comandos em `docs/gold_fontes_infra.md`). Quase tudo está no **GeoSampa**, aberto (CC BY-SA 4.0), por WFS público ou arquivo pronto, em SIRGAS 2000 / UTM 23S (EPSG:31983). O Databricks não alcança esses servidores: baixar no PC e subir para o volume (`bronze/raw/infra/`).

Atributo (hipótese da literatura)	Fonte	Variável por trecho
Tipo de via (vias rápidas/arteriais perdem mais em %)	Classificação Viária CET (GeoSampa; 210.754 trechos de logradouro; revisão 02/2026)	fração do trecho por classe (VTR, arterial, coletora, local) e classe dominante
Faixa exclusiva (atenua)	`faixa_onibus` (7.378 feições, ~779 km; data de implantação; horário)	fração do trecho com faixa; só pico ou integral
Corredor (atenua)	`corredor_onibus` (45 linhas, ~265 km; 40 em operação)	fração do trecho em corredor
Histórico de alagamento (perdas de 20–40%, recuperação lenta)	Ocorrências da Defesa Civil 2013–2026 (pontos com data; ALAGAMENTO/INUNDAÇÃO)	ocorrências por km por ano num raio de 50–100 m
Alagamento por evento (opcional)	CGE, histórico diário desde ~2008 com hora e transitável/intransitável (HTML, exige scraping e geocodificação)	casar com os eventos de chuva hora a hora
Suscetibilidade (complemento)	manchas de inundação TR 5/25/100 (modeladas), córregos canalizados, declividade	fração do trecho em mancha; proximidade de córrego canalizado
Contexto (opcional)	Censo 2022, entorno por setor (bueiro, pavimentação)	média ponderada no entorno

Como juntar: geometria de cada trecho físico = pedaço do traçado GTFS entre as duas paradas, reprojetado para EPSG:31983; para camadas lineares, recorte por buffer (12–15 m vias, 15–20 m faixas, 20–25 m corredores) com filtro de rumo (< 30°) para não pegar ruas transversais; pontos contados num raio; polígonos por fração do comprimento.

Análise: os atributos entram como covariáveis no estágio 2 do KR3 (efeito do trecho ~ Xγ); γ responde ao KR4. Sensibilidade: classe dominante vs. frações; e a interação com a recuperação (KR2) por análise de sobrevivência.

Ressalvas: faixas exclusivas desatualizadas (metadados de 2021, última implantação 01/2024) — usar a data de implantação; pontos da Defesa Civil geocodificados pelo endereço do chamado e subnotificados; manchas de inundação são modeladas, não observadas.

2.8 KR5 — previsão (aspiracional)

- **Alvo:** anomalia em t+10 … t+60 min (ou "queda > x%"), por trecho ou corredor.
- **Atributos:** chuva observada com defasagens 0–60 min e acumulados 1–3 h; chuva nos postos vizinhos e fração da cidade chovendo; anomalia atual do trecho e dos vizinhos a montante/jusante; hora e tipo de dia; infraestrutura; sensibilidade do trecho **estimada só com os dias de treino**.
- **Modelos:** primeiro as referências (persistência e perfil histórico); depois ridge e *gradient boosting* (LightGBM).
- **Avaliação:** validação **por blocos de dias inteiros, em ordem temporal** (forward chaining) — validação aleatória superestima; métricas separadas em seco, chuva leve, chuva forte e pós-chuva; ganho sobre a persistência.
- Limite: só com chuva observada, o modelo não antecipa células que ainda não chegaram; nowcasting por radar seria a extensão.

2.9 Cuidados que viram análises

- **Erro de medida da chuva** (posto a 1,6 km; báscula subestima intensidades altas) puxa o efeito para zero: testar a interação efeito × distância ao posto e o posto mais próximo com teto de 2, 3 e 5 km. O efeito deve crescer quando o posto está mais perto.
- **Dado faltante informativo:** em alagamento os ônibus somem do trecho (desviados ou parados) exatamente no pior momento. Analisar também o **número de passagens** como desfecho, e rodar com e sem `parado_longo`.
- **Calendário:** feriados (07/09 e 12/10, segundas), eleição (04/10, domingo), suspensão do rodízio em dias de chuva forte (ex.: 14/10, 17h–20h), greves e jogos — marcar e testar a exclusão.
- **Métrica:** % (log) é a principal; para somar ao longo de uma rota, usar *pace* (s/km), que é aditivo.
- **Mecanismos misturados:** o efeito é na velocidade comercial (tráfego + embarque), não "do trânsito".

3. Tabelas propostas

Tabela	Grão	Conteúdo
`gold.trecho`	trecho físico	coordenadas, comprimento, linhas, postos atribuídos (pesos e distâncias); depois, atributos de infraestrutura (KR4)
`gold.chuva_posto_10min`	posto × slot	intensidades em 30/60 min, acumulado 3 h, minutos desde o fim, `evento_id`
`gold.evento_chuva`	evento	posto, início, fim, duração, total, pico
`gold.obs_trecho_10min`	trecho × janela	Σd, Σt, velocidade, n_pares, chuva atribuída, linha de base, razão
`gold.efeito_cidade`	classe × período	KR1 e KR2 da cidade, com IC
`gold.efeito_trecho`	trecho	efeito bruto, efeito com encolhimento, IC, frequência no top-10/20, dados usados

4. Riscos e cuidados

- **Ruído por janela** (2 passagens na mediana): sempre agregar; nunca concluir de janelas isoladas.
- **Dependência dentro do dia:** erros-padrão e ranking por bootstrap de dias, não de janelas.
- **Linha de base variando** com dia da semana e semana: ajustar (seção 2.4).
- **Rede CEMADEN:** fora das variáveis de tempo.
- **Ônibus presos em alagamento:** a regra `parado_longo` (≥ 20 min) pode remover justamente os piores casos; rodar o KR1/KR3 com e sem eles.
- **Validade externa:** setembro de 2026 foi o mais chuvoso da série, com chuva frontal persistente; o efeito de temporais convectivos de verão pode ser diferente.
- **Trechos com razão absurda** (0 ou > 10): dado insuficiente ou trecho mal formado; a regra de dado mínimo resolve a maioria.