Ônibus SP × Chuva

O projeto do começo ao fim: da coleta na API aos resultados

Gabriel Graciano Dias · IME-USP / MAE0350
02/11/2026

Sumário

Como ler este documento 4

1. O projeto 5
- 1.1 A pergunta 5
- 1.2 Os KRs 5
- 1.3 As fontes de dados 6
- 1.4 Como os dados fluem 6
- 1.5 Quatro hábitos usados em todas as etapas 7

2. Coleta: da API para a VM 8
- 2.1 A API Olho Vivo 8
- 2.2 A VM 8
- 2.3 A linha do tempo da coleta 9
- 2.4 O que se perde na coleta 9
- 2.5 Os outros coletores 9
- 2.6 Decisões da coleta 10

3. Organização no Databricks 11
- 3.1 O que existe 11
- 3.2 O limite que definiu a ingestão 11
- 3.3 Como os notebooks se comportam 11
- 3.4 Decisões da organização 12

4. Bronze: o que a API disse 13
- 4.1 A regra da camada 13
- 4.2 Notebook 00: do Drive para o volume 13
- 4.3 Notebook 01: dos arquivos para a tabela 13
- 4.4 A tabela 14
- 4.5 Um exemplo real 14
- 4.6 Decisões da bronze 15

5. Silver: o GTFS 16
- 5.1 O que é e para que serve 16
- 5.2 A ponte com a API 16
- 5.3 Versões 16
- 5.4 Leitura e checagens 17
- 5.5 Decisões do GTFS 17

6. Silver: posições limpas 18
- 6.1 O que o notebook 03 faz 18
- 6.2 O que ganha cada posição 18
- 6.3 As linhas de sentido único 19
- 6.4 Conferência do fuso 19
- 6.5 Decisões das posições limpas 19

7. Silver: posições na rota 20
- 7.1 A ideia da régua 20

7.2 A projeção 20
7.3 Traçados que passam duas vezes pela mesma rua 20
7.4 O que sobra e o que foi medido 21
7.5 Decisões da projeção 21
8. Silver: deslocamentos 22
8.1 O par como unidade 22
8.2 Ecos 22
8.3 As situações 22
8.4 `parado_longo`: a história da madrugada 23
8.5 Como a regra foi validada 23
8.6 Decisões dos deslocamentos 24
9. Silver: velocidade por trecho 25
9.1 O que é um trecho 25
9.2 Parte A: `gtfs_trechos` 25
9.3 Parte B: o rateio 25
9.4 Checagens e números 26
9.5 Trecho físico 26
9.6 Decisões da velocidade 27
10. Silver: chuva 28
10.1 A fonte 28
10.2 As três redes 28
10.3 O notebook 07 28
10.4 Qualidade dos postos 29
10.5 Um período incomum 30
10.6 Decisões da chuva 30
11. Automação e dashboard 31
11.1 O job diário 31
11.2 O que fica fora do job 31
11.3 Dashboard 31
11.4 Decisões da automação 31
12. Gold: visão geral 32
12.1 O que a gold faz 32
12.2 O que a exploração mostrou 32
12.3 Comparação com a literatura 33
12.4 Decisões gerais da gold 33
13. Gold: a base (notebook 08) 34
13.1 Trechos 34
13.2 Os postos de cada trecho 34
13.3 Chuva por posto 34
13.4 Eventos de chuva 35
13.5 Checagens 35
13.6 Decisões da base 35
14. Gold: observações e linha de base (notebook 09) 36
14.1 A tabela de observações 36
14.2 Classes de chuva 36
14.3 A velocidade normal 36
14.4 A razão 37
14.5 Checagens 37
14.6 Dois erros pegos aqui 37
14.7 Decisões das observações 38
15. KR1 e KR2 na cidade (notebook 10) 39

15.1 Como sai o intervalo de confiança 39
15.2 KR1: quanto cai 39
15.3 Antecipação 40
15.4 KR2: recuperação 40
15.5 Decisões do notebook 10 42
16. Infraestrutura (notebook 11) 43
16.1 Os dados 43
16.2 Como juntar 43
16.3 Atributos de cada trecho 43
16.4 Validação 44
16.5 Decisões da infraestrutura 44
17. Efeito por trecho, ranking e infraestrutura (notebook 12) 45
17.1 A regra [N] 45
17.2 Estágio 1: o efeito de cada trecho 45
17.3 Estágio 2: o encolhimento 45
17.4 Resultado do KR1 por trecho 46
17.5 KR3: o critério reprovou 46
17.6 O que é estável: o grupo crítico 46
17.7 KR4: tipo de via 48
17.8 KR4: histórico de alagamento 49
17.9 KR4: faixa, corredor e outros atributos 50
17.10 Decisões do notebook 12 50
18. Recuperação por trecho e por grupo (notebook 13) 51
18.1 O limite do que dá para medir 51
18.2 Por trecho: faixas de tempo 51
18.3 Isso se repete em outros dias? 51
18.4 Os piores demoram cerca do dobro 52
18.5 Por grupo: tempo e perda 52
18.6 Decisões do notebook 13 53
19. Os KRs: como alcançamos e em que pé estamos 54
19.1 Quadro geral 54
19.2 KR1: redução da velocidade durante a chuva 54
19.3 KR2: tempo de recuperação 55
19.4 KR3: os 10 trechos mais afetados 55
19.5 KR4: infraestrutura 56
19.6 KR5: previsão 56
20. Limitações 57
20.1 O período 57
20.2 A medição 57
20.3 A interpretação 57
20.4 O que foi planejado e ainda não foi feito 58
21. Próximos passos 59
21.1 Decisões para o Rafael 59
21.2 Novo download da chuva 59
21.3 Tarefas técnicas 59
Apêndice A. Como rodar tudo de novo 60
Apêndice B. As tabelas 61
Apêndice C. Glossário 63
Apêndice D. Problemas encontrados e como foram resolvidos 65

Como ler este documento

Este documento acompanha os dados na ordem em que passam pelo projeto: saem da API da SPTrans, viram tabelas no Databricks e terminam nos resultados dos KRs. Cada capítulo diz o que a etapa recebe, o que faz, o que entrega, o que foi medido e quais decisões foram tomadas. No fim de quase todo capítulo há uma tabela com essas decisões e o motivo de cada uma.

Os capítulos 1 a 3 apresentam o projeto, a coleta e a organização no Databricks. Os capítulos 4 a 11 cobrem a bronze e a silver. Os capítulos 12 a 18 cobrem a gold. O capítulo 19 reúne os KRs, como cada um foi alcançado e em que pé está. Os capítulos 20 e 21 tratam das limitações e do que falta. Os apêndices trazem a ordem para rodar tudo de novo, a lista de tabelas, um glossário e os problemas encontrados pelo caminho.

Algumas convenções valem para o documento inteiro:

- **Períodos.** Os dados de ônibus vão de 25/08 a 01/11/2026, e o job diário continua acrescentando dias. A chuva vai até 25/10, então todas as análises da gold vão de 25/08 a 25/10.
- **Nomes de tabela.** As tabelas estão no catálogo `onibus`. O texto escreve `silver.deslocamento` no lugar de `onibus.silver.deslocamento`.
- **Horários.** Os horários citados são de São Paulo. Quando um dado está em UTC, o texto avisa.
- **Razão.** A partir do capítulo 14, a medida principal é a razão entre a velocidade observada e a velocidade esperada para aquele trecho e horário. Razão 1 é o normal, e 0,90 é 10% mais lento que o normal.

1. O projeto

1.1 A pergunta

O objetivo, definido com o Rafael, é **identificar onde a chuva mais degrada a malha de ônibus de São Paulo e quais elementos da infraestrutura estão associados a essa perda**. O projeto está vinculado à disciplina MAE0350 do IME-USP, com reunião semanal às segundas.

A pergunta passou por três versões. A primeira media a regularidade do intervalo entre ônibus por linha. A segunda perguntava quanto da variância do tempo de espera era explicada pela chuva. A atual usa a **velocidade dos ônibus por trecho** como medida principal.

A velocidade usada é a comercial: inclui paradas em ponto e em semáforo, que é o que o passageiro sente. A chuva funciona como tratamento, porque ninguém a decide olhando o trânsito. Duas dificuldades permanecem. Chuva forte costuma cair em certos horários, e cada horário tem sua própria velocidade normal. Além disso, janelas do mesmo dia não são independentes, porque a mesma frente fria atinge milhares de trechos ao mesmo tempo. Boa parte do desenho da gold existe para lidar com essas duas questões.

1.2 Os KRs

Os resultados-chave seguem o formato de OKR do Rafael, em que cada KR recebe uma nota de 0 a 1.

KR	Enunciado
KR1	Quantificar a redução da velocidade durante a chuva em pelo menos [N] trechos
KR2	Quantificar o tempo de recuperação da velocidade após a chuva em pelo menos [N] trechos
KR3	Identificar os 10 trechos mais afetados, com ranking estatisticamente estável
KR4	Avaliar a associação entre degradação e dois atributos de infraestrutura: tipo de via e histórico de alagamento
KR5 (aspiracional)	Prever a degradação dos trechos na hora seguinte a partir da chuva observada

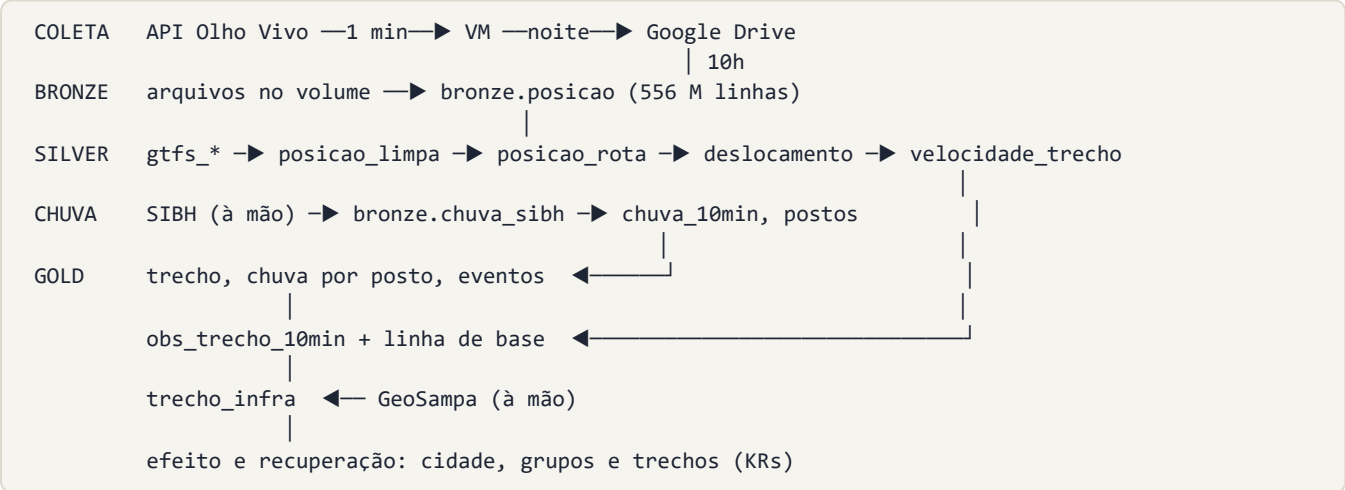
O [N] virou uma regra de dado mínimo por trecho, definida no capítulo 17. O capítulo 19 retoma cada KR com o resultado.

1.3 As fontes de dados

Fonte	O que traz	Frequência	Uso
API Olho Vivo (SPTrans)	posição de cada ônibus	1 min (2 min até 20/09)	velocidade
GTFS (SPTrans)	linhas, traçados e paradas	versões baixadas à mão	transformar posição em metro da rota, definir trechos
SIBH (DAEE/SP Águas)	chuva por posto	10 min	tratamento
GeoSampa (Prefeitura)	tipo de via, faixas, corredores, ocorrências	versão de 02/11	KR4
KMZ (SPTrans) e **lentidão CET**	velocidade oficial em vias e lentidão por região	1 min e 10 min	coletados para validação, ainda sem uso

1.4 Como os dados fluem

O projeto usa a arquitetura medalhão, com três camadas. A **bronze** guarda o que a fonte disse. A **silver** limpa e enriquece, descrevendo o que aconteceu de fato. A **gold** cruza velocidade e chuva e responde aos KRs.



Cada etapa é um notebook numerado, e a ordem dos números é a ordem de execução:

Notebook	Camada	Entrega
`00_ingestao_drive`	bronze	copia os arquivos do Drive para o volume
`01_bronze_posicao`	bronze	`bronze.posicao`
`02_silver_gtfs`	silver	`silver.gtfs_*`
`03_silver_posicao_limpa`	silver	`silver.posicao_limpa`, `silver.quarentena_posicao`
`04_silver_posicao_rota`	silver	`silver.posicao_rota`
`05_silver_deslocamento`	silver	`silver.deslocamento`

Notebook	Camada	Entrega
`06_silver_velocidade_trecho`	silver	`silver.gtfs_trechos`, `silver.velocidade_trecho`
`07_silver_chuva`	bronze e silver	`bronze.chuva_sibh`, `silver.chuva_10min`, `silver.postos`
`08_gold_base`	gold	trechos, postos de cada trecho, chuva por posto, eventos
`09_gold_obs_base`	gold	observações, linha de base, razão
`10_gold_efeito_cidade`	gold	KR1 e KR2 na cidade
`11_gold_trecho_infra`	gold	infraestrutura por trecho
`12_gold_efeito_trecho`	gold	KR1, KR3 e KR4 por trecho
`13_gold_recuperacao_trecho`	gold	KR2 por trecho e por grupo
`metadados`	todas	descrição de cada tabela e coluna

1.5 Quatro hábitos usados em todas as etapas

Toda tabela confere com a anterior. Cada notebook faz uma conta que tem que fechar. Na bronze, as linhas do dia têm que ser iguais ao que a auditoria da coleta registrou. Na silver, `bronze = limpa + quarentena`. Se a conta não fecha, o notebook falha. Foi assim que apareceram quase todos os problemas listados no apêndice D.

As regras marcam, e os dados ficam. Uma regra de qualidade vira uma coluna, como `situacao`, `motivo`, `status` ou uma flag. As linhas continuam na tabela, o que permite mudar a regra depois e medir o efeito da mudança.

Primeiro um pedaço pequeno. Cada lógica nova rodou antes em um dia e poucas linhas de ônibus, com gráficos para olhar, ou em dados sintéticos no PC. Só depois foi para a base inteira.

Tudo fica escrito. Cada tabela e coluna tem descrição no catálogo. Os notebooks explicam suas regras no próprio texto. O repositório guarda o código, os documentos em `docs/` e o `CLAUDE.md`, que resume o estado do projeto.

2. Coleta: da API para a VM

2.1 A API Olho Vivo

A API da SPTrans mostra a situação atual dos ônibus e não guarda histórico. Quem quer o passado precisa ter gravado no momento em que aconteceu. Por isso existe a coleta: uma máquina consulta a API sem parar e guarda cada resposta.

A autenticação é um `POST /Login/Autenticar?token=...`, que devolve `true` e um cookie de sessão. O POST exige `Content-Length: 0` explícito, senão a API responde 411. A consulta `/Posicao` devolve todas as linhas em circulação, cada uma com seus veículos:

Campo	Significado
`p`	prefixo do veículo: identifica o ônibus físico
`ta`	instante da posição na fonte, em UTC
`py`, `px`	latitude e longitude
`c`	letreiro da linha, igual ao `route_id` do GTFS
`cl`	código interno de linha + sentido
`sl`	sentido (1 ou 2)
`lt0`, `lt1`	os dois terminais da linha
`a`	veículo acessível
`qv`	número de veículos da linha

Medições feitas com os dados coletados mostram como a fonte se comporta:

- A SPTrans atualiza as posições a cada ~45 segundos. Consultando a cada minuto, capturamos cerca de 75% das atualizações.
- A idade da posição tem mediana de 22 s.
- As posições já vêm encaixadas no traçado pela SPTrans: 99,8% têm erro lateral de 0,00 m. O dado descreve “posições publicadas pelo operador”, e o erro lateral não serve como controle de qualidade.
- A frota tem ~8.900 veículos em média e ~11.200 no pico.
- A API não informa velocidade. Os campos `sv` e `is` existem na resposta, mas vêm sempre nulos.

2.2 A VM

A coleta roda numa VM da DigitalOcean (Ubuntu 24.04, 1 vCPU, 512 MB, US$ 4 por mês), em Nova York, no usuário `gabriel`. O script `coletor.py` é executado por um timer do systemd a cada minuto. Cada ciclo faz login, consulta `/Posicao`, grava o resultado e acrescenta uma linha em `auditoria.csv`.

A auditoria é o batimento cardíaco da coleta. Ela registra o instante do ciclo, o status, quantos veículos vieram, o arquivo gravado e o erro, se houve. Mais adiante, a bronze é conferida contra ela, linha a linha.

A cada noite, às 5h UTC, o `backup.sh` usa o `rclone` para mandar os dados ao Google Drive, na pasta `olhovivo-bronze`. Arquivos com mais de 48 horas são movidos, o que libera o disco da VM, e os mais novos são copiados. Assim o Drive sempre tem o dia anterior completo quando o Databricks vai buscar.

2.3 A linha do tempo da coleta

Quando (UTC)	O que mudou
25/08 22:18	início da coleta, a cada 2 min, em formato achatado (v1)
21/09 02:51	início do coletor da lentidão CET
21/09 02:55	cadência passa para **1 min**
21/09 ~03:06	formato passa a ser a **resposta crua** da API (v2)
27/09 21:36	início do coletor KMZ
27/09 21:46	coletor corrigido: novas tentativas quando a API devolve `null`, login auditado, token mascarado no log

A diferença entre os formatos aparece no capítulo 4. Na v1, o coletor já transformava a resposta em uma linha por ônibus e tirava duplicatas. Na v2, ele guarda a resposta exatamente como veio, e todo tratamento fica para depois.

2.4 O que se perde na coleta

Entre 21/09 e 27/09, a auditoria mostrou 9.697 ciclos, com 118 respostas `null` e 38 ciclos sem registro por falha de login, ou cerca de 1,6% de perda. Na auditoria do início da coleta, os 163 erros eram todos a API devolvendo HTTP 200 com corpo `null`. O maior buraco entre ciclos bons foi de 8,5 min até 13/09.

Houve uma falha grande da fonte: no **domingo 11/10, das ~6h às ~13h**, a API respondeu 503 no login. Esse dia tem poucas posições, mas nenhum dia útil teve falha parecida.

2.5 Os outros coletores

Dois coletores rodam em paralelo e ainda não entraram na análise. O `coletor_kmz.py` guarda a velocidade oficial por trecho de via que a SPTrans publica. O `coletor_cet.py` guarda a lentidão por região do site da CET, que atualiza a cada 30 min. Os dois servem para validar a velocidade calculada aqui, com uma fonte externa.

2.6 Decisões da coleta

Decisão	Motivo
Coletar numa VM própria e barata	a API não tem histórico, e a rede do Databricks não alcança a SPTrans (seção 3.2)
Passar de 2 min para 1 min	capturar mais atualizações da fonte, que atualiza a cada ~45 s
Guardar a resposta crua a partir de 21/09	manter a fonte intacta e deixar o tratamento para as camadas seguintes
Manter o token da SPTrans	decisão do Gabriel em 27/09: baixo risco, e o log passou a mascarar o valor
Guardar tudo no Drive pessoal de 2 TB	já estava disponível, com espaço de sobra para o projeto

3. Organização no Databricks

3.1 O que existe

O workspace usa **Unity Catalog** com um catálogo, `onibus`, e três schemas: `bronze`, `silver` e `gold`. Os arquivos crus ficam no volume `bronze.raw`, em pastas:

```
/Volumes/onibus/bronze/raw/
├── olhovivo/        posições (bronze_posicao/ = v1, bronze_raw/ = v2) e auditoria.csv
├── gtfs/            versao=AAAA-MM-DD/
├── chuva/sibh/      download=2026-10-25/ (18 CSVs, stations.json, manifesto.csv)
└── infra/           versao=2026-11-02/ (GeoSampa e manifesto.csv)
```

As tabelas são Delta e particionadas por `dt`, o dia. O processamento roda em **serverless**, sem cluster para administrar. Os notebooks ficam em `/Users/diasg270@gmail.com/onibus/` e no GitHub, em repositório privado.

O plano é Enterprise, ativado por engano em 04/10, com US$ 1.000 em créditos válidos até 23/09/2027. Esse plano tem unidade de processamento mais cara, e manter ou trocar de plano está entre as perguntas para o Rafael.

3.2 O limite que definiu a ingestão

O serverless deste workspace tem saída de rede restrita. Nos testes de 03/10, alcançou `pypi.org` e `*.googleapis.com` e não alcançou a API da SPTrans. Mesmo depois do plano Enterprise, a tentativa de liberar o domínio da SPTrans não funcionou.

Daí veio o desenho final: a **VM coleta e guarda no Drive, e o Databricks busca no Drive**. A API do Drive está em `googleapis.com`, então é alcançável. O GeoSampa e o SIBH também estão fora do alcance, por isso são baixados no PC e enviados ao volume.

3.3 Como os notebooks se comportam

Vários padrões se repetem e valem a explicação uma vez só.

Parâmetro `dias`. Os notebooks 03 a 06 aceitam um widget: vazio processa tudo, uma lista processa aqueles dias, e `ontem` processa o dia anterior em São Paulo. O job usa `ontem`.

Idempotência. Com `dias` preenchido, a gravação usa `replaceWhere`, que troca só as partições daqueles dias. Rodar duas vezes dá o mesmo resultado, e dá para reprocessar um dia sem tocar nos outros.

Modo teste. Os notebooks 05 e 06 têm o widget `linhas`. Preenchido, roda poucas linhas e só mostra os resultados. Vazio, grava.

Pandas dentro do Spark. A lógica mais difícil (projetar posições, ratear pares) é escrita em pandas e numpy e aplicada por grupo com `applyInPandas` e `cogroup`. Um grupo é um traçado em um dia.

Checagens. Toda checagem que não fecha levanta erro, e o run fica vermelho.

Metadados. O notebook `metadados` é a fonte única das descrições. Gravar com `overwriteSchema` apaga os comentários das colunas, então cada notebook termina com `%run ./metadados` e `aplicar_metadados(tabela)`.

3.4 Decisões da organização

Decisão	Motivo
Databricks puxa do Drive com uma conta de serviço	a rede alcança `googleapis.com`, e dá para carregar o histórico sem depender do PC
Chave da conta de serviço em secret (`onibus/gdrive_sa`)	a chave nunca aparece em código, e o robô só tem leitura na pasta
Partição por dia em todas as tabelas de posição	reprocessar um dia sem refazer o resto
Um notebook por etapa, numerado	a ordem de execução fica evidente
Descrições em um notebook único	evita descrição divergente entre notebooks

4. Bronze: o que a API disse

4.1 A regra da camada

A bronze responde a uma pergunta: o que a fonte disse? Ela guarda os dados sem limpeza, sem correção e sem cruzar com nada. Se uma regra da silver estiver errada, tudo pode ser refeito a partir dela.

4.2 Notebook 00: do Drive para o volume

O `00_ingestao_drive` copia os arquivos de um dia. Ele se autentica como o robô, transforma a chave num token temporário de cerca de 1 hora, com escopo só de leitura, e desce pelas pastas do Drive até a do dia. Baixa em paralelo, com threads, porque cada arquivo é pequeno e quase todo o tempo é espera de rede. Arquivo que já existe no volume com o mesmo tamanho é pulado, então rodar duas vezes não duplica nada.

O passo final confere se **todo arquivo que a auditoria diz que existe está no volume**. Essa conferência existe por causa de um problema real: a listagem do Drive às vezes vinha incompleta, com 1.392 de 1.439 arquivos. O notebook repete a listagem e tenta de novo com espera crescente quando a API falha.

Para o histórico, o job `backfill_drive` usou uma tarefa For each sobre a lista de dias em `jobs/backfill_inputs.json`, levou 25 minutos e rodou uma vez.

4.3 Notebook 01: dos arquivos para a tabela

O `01_bronze_posicao` junta os dois formatos numa tabela com **uma linha por ônibus por ciclo**.

	v1 (25/08 a 21/09)	v2 (21/09 em diante)
Pasta	`bronze_posicao/`	`bronze_raw/`
Arquivo	`.ndjson.gz`, já achatado	`.json.gz`, resposta inteira da API
Ciclo	~2 min	1 min
Duplicatas	tiradas pelo coletor	mantidas

O schema é declarado no código. O Spark não precisa ler tudo para adivinhar os tipos, e uma mudança da SPTrans aparece como erro. Na v2, a resposta é aninhada, e dois `explode` a abrem: resposta, linhas, veículos. O instante da coleta vem do nome do arquivo. Na v1, `p` vem como texto e vira número. As duas partes se juntam com `unionByName`, e a coluna `formato` diz de onde veio cada linha. A única coisa descartada são os arquivos `null`, que não têm conteúdo.

A checagem compara, por dia, as linhas da tabela com a soma de `veiculos_gravados` dos ciclos bons da auditoria. A diferença tem que ser zero, e foi zero em todos os dias.

4.4 A tabela

Coluna	O que é
`dt`	dia de São Paulo do ciclo (partição)
`coletado_em`	quando a VM recebeu, em UTC
`ta`	quando a SPTrans registrou a posição, em UTC
`p`	o ônibus físico
`c`, `cl`, `sl`	linha, código interno, sentido
`py`, `px`	latitude, longitude
`arquivo`, `formato`	arquivo de origem e versão do formato

Hoje são **556,2 milhões de linhas** em 69 dias: 122,5 M na v1 e 433,7 M na v2.

Três campos sustentam o projeto: `p`, `ta` e a posição. O mesmo `p` ao longo de vários `ta` forma uma trajetória.

4.5 Um exemplo real

O ônibus 48874, da linha 507T (Metrô Carrão ↔ Terminal Sapopemba), chegando ao terminal em 29/09, com horário de SP:

08:00:22	2	−23,60605	−46,50314
08:01:52	2	−23,60955	−46,50136
08:02:37	2	−23,61200	−46,50138
08:03:58	2	−23,61391	−46,50091
08:04:50	**1**	−23,61412	−46,50123
08:05:35	1	−23,61412	−46,50123
08:06:20	1	−23,61412	−46,50123

Nessa pequena tabela já estão várias regras da silver. O ônibus anda para o sul nas quatro primeiras linhas. Às 08:04 chega ao terminal e troca de sentido. Depois fica parado com `ta` avançando: a linha muda, mas o ônibus não sai do lugar. Se isso entrasse na velocidade, viraria 0 km/h sem nada a ver com chuva. O intervalo entre posições também varia (90, 45, 81, 52 segundos), porque a fonte atualiza em um ritmo e nós consultamos em outro.

4.6 Decisões da bronze

Decisão	Motivo
Nenhuma limpeza na bronze	permite refazer tudo se uma regra posterior estiver errada
Dois formatos numa tabela só, com coluna `formato`	a silver lê uma fonte única, e as diferenças ficam rastreáveis
Schema explícito	leitura mais rápida, e mudança na fonte vira erro visível
Conferir contra a auditoria	a auditoria é uma contagem independente da tabela
Usar `ta` como relógio da velocidade	é o instante da posição na fonte; `coletado_em` só diz quando a VM recebeu

5. Silver: o GTFS

5.1 O que é e para que serve

A silver responde a outra pergunta: o que aconteceu de fato? Para saber onde um ônibus estava na rota, é preciso conhecer a rota. Essa informação vem do GTFS, o formato padrão de dados de transporte público, que a SPTrans publica para download sem login.

O `02_silver_gtfs` lê os arquivos e grava uma tabela por arquivo:

Tabela	Uma linha é	Uso
`gtfs_routes`	uma linha de ônibus	`route_id` é o `c` da API
`gtfs_trips`	uma viagem-modelo	linha + sentido levam ao traçado (`shape_id`)
`gtfs_shapes`	um ponto do traçado	a régua da rota, com distância acumulada em metros
`gtfs_stops`	uma parada	posição das paradas
`gtfs_stop_times`	uma parada de uma viagem	ordem das paradas, de onde saem os trechos
`gtfs_frequencies`	uma faixa horária	intervalo programado, para uso secundário
`gtfs_calendar`	um tipo de serviço	dias de operação
`gtfs_versao`	uma versão	qual versão usar em cada dia

A coluna mais importante é `shape_dist_traveled`, em `gtfs_shapes`. Ela diz a quantos metros do início da rota está cada ponto do traçado, e é a régua usada no capítulo 7.

São 1.361 linhas e 2.271 viagens-modelo, uma por traçado. O GTFS da SPTrans é baseado em frequência: traz intervalos por faixa horária, sem horário exato de cada viagem.

5.2 A ponte com a API

Dois encaixes ligam a API ao GTFS. O campo `c` é igual a `route_id` em 99,8% das linhas. O sentido foi validado projetando posições nos dois traçados possíveis: `sl = 1` corresponde a `direction_id = 0`, e `sl = 2` a `direction_id = 1`. Nos 647 grupos decisivos, não houve contraexemplo.

5.3 Versões

O GTFS muda com o tempo. Entre as versões de 26/08 e 12/10, 882 dos 2.188 traçados em comum mudaram (a maioria em menos de 15 m, mas 21 em mais de 500 m), 83 viagens trocaram de traçado e 612 das 2.271 mudaram a sequência de paradas.

Por isso cada versão fica guardada, identificada pela data do download, e `gtfs_versao` diz qual vale para cada dia:

Versão	Vale de	Até
2026-08-26	25/08	11/10
2026-10-12	12/10	hoje

A limitação é que sabemos quando baixamos, e não quando a SPTrans mudou. Na semana anterior a um download, parte dos traçados pode estar desatualizada. O erro lateral cresce com o tempo (seção 7.4), o que indica que vale baixar uma versão nova.

5.4 Leitura e checagens

A leitura usa schema explícito, confere o cabeçalho (`enforceSchema=False`) e falha diante de um valor fora do tipo (`FAILFAST`). Identificadores e horários ficam como texto, porque horários do GTFS podem passar de 24:00:00 em viagens que viram a noite.

O notebook falha se o número de linhas do arquivo não bater com o da tabela, se uma chave tiver nulo ou repetição, ou se uma referência apontar para algo que não existe, como uma viagem com `shape_id` inexistente.

5.5 Decisões do GTFS

Decisão	Motivo
Guardar todas as versões, com coluna `versao`	o traçado certo depende do dia
Cada versão vale do seu download até a véspera da seguinte	é a informação disponível sobre quando a mudança ocorreu
`sl = direction_id + 1`	validado com dados nos dois traçados
Tipos e cabeçalho conferidos na leitura	uma mudança de formato vira erro, e não dado trocado de coluna

6. Silver: posições limpas

6.1 O que o notebook 03 faz

O `03_silver_posicao_limpa` recebe a bronze e separa cada posição em dois destinos: `silver.posicao_limpa`, com as que passam, e `silver.quarentena_posicao`, com as que não passam e o motivo. Nada some. A checagem, por dia, é `bronze = limpa + quarentena`.

Cada posição recebe o primeiro motivo que se aplica, nesta ordem:

Motivo	Regra	Posições	% da bronze
`duplicata`	mesmo `(p, ta)` mais de uma vez; fica a primeira coleta	4.858.647	0,87%
`coordenada_invalida`	latitude ou longitude nula ou fora da caixa de SP	0	0%
`ta_no_futuro`	`ta` mais de 60 s depois de `coletado_em`	202.135	0,04%
`posicao_velha`	`coletado_em − ta` maior que 5 min	256.070	0,05%
`linha_sem_shape`	a linha não tem viagem no GTFS do dia	2.201.012	0,40%
`sentido_sem_shape`	a linha tem dois sentidos, mas não o da API	0	0%

Sobram **548,7 milhões de posições** (98,65%), e 7,5 milhões vão para a quarentena.

Algumas regras têm uma história própria. A duplicata pode ter até 220 repetições: é um ônibus "congelado" na API. O limite de 60 s em `ta_no_futuro` existe porque, na v2, `coletado_em` é o início do ciclo, e a requisição pode levar até ~46 s, então um `ta` depois de `coletado_em` é normal dentro desse limite. As linhas sem traçado são 55: serviços especiais como `PAEC-10` e `TREI-10` e cerca de 37 variantes que aparecem em `routes.txt` sem viagens.

6.2 O que ganha cada posição

Horário de SP. `ta_sp` é o horário de parede de São Paulo. `ta` continua em UTC.

Tipo de dia. `tipo_dia` vale `util`, `sabado`, `domingo` ou `feriado`, pela data de `ta_sp`. Os feriados do período estão no notebook: 07/09, 12/10, 02/11, 15/11, 20/11 e 25/12. Em feriado, os ônibus operam com tabela de domingo.

Traçado. A posição recebe o `shape_id` certo, a partir da linha, do sentido e da versão do GTFS do dia.

6.3 As linhas de sentido único

Cerca de 370 linhas têm um traçado só no GTFS: são as circulares. A API manda `sl = 1` e `sl = 2` nelas também, mas os dois caem em cima do mesmo traçado (erro lateral de 0 m na mediana, no teste com 8 linhas). Essas linhas usam o traçado único e ganham `sentido_unico = true`. No capítulo 8, uma troca de `sl` nelas deixa de significar troca de viagem.

6.4 Conferência do fuso

A frota por hora em 08/10 mostrou picos entre 7h e 9h e entre 17h e 19h no horário de São Paulo, como esperado. A checagem veio de um alerta da literatura: um estudo de Niterói mostrava picos três horas antes do normal, sinal de fuso aplicado duas vezes.

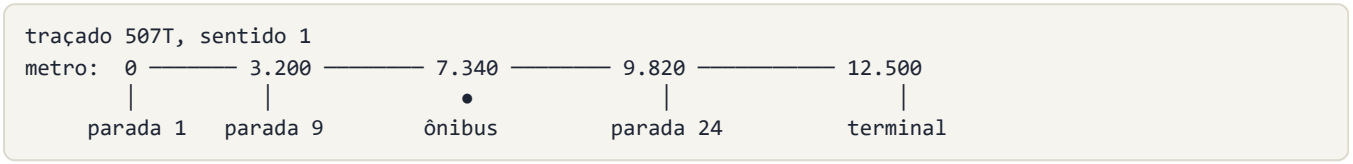
6.5 Decisões das posições limpas

Decisão	Motivo
Quarentena com motivo	toda posição descartada fica contada e pode ser reavaliada
Dedupe por `(p, ta)`, ficando a primeira coleta	a primeira é a mais recente em relação a `ta`
Caixa de SP, com margem	guarda contra coordenada absurda; hoje não pega nada
`tipo_dia` pela data de `ta_sp`	perto da meia-noite, `dt` e a data de `ta_sp` podem diferir
Feriado tratado como dia de tabela de domingo	é como os ônibus operam

7. Silver: posições na rota

7.1 A ideia da régua

Uma posição em latitude e longitude é difícil de usar para medir velocidade numa rota com curvas. O `04_silver_posicao_rota` transforma o mapa em uma régua: cada posição vira "o ônibus está no metro *d* da rota".



A tabela mantém o mesmo número de linhas da `posicao_limpa`, e cada posição ganha colunas:

Coluna	O que é
`d_m`	metro ao longo do traçado
`erro_lateral_m`	distância da posição até o traçado
`n_candidatos`	quantas passagens do traçado estavam ali
`comprimento_m`	comprimento total do traçado

7.2 A projeção

A posição é projetada ortogonalmente no traçado, num plano equirretangular centrado em São Paulo, com erro abaixo de 0,1% em 50 km. O metro sai da interpolação de `shape_dist_traveled` no segmento mais próximo. O código usa `cogroup` por versão, traçado e dia, e um grupo tem menos de ~60 mil posições.

7.3 Traçados que passam duas vezes pela mesma rua

Se um traçado passa duas vezes pelo mesmo lugar, "o ponto mais próximo" é ambíguo. No GTFS de 12/10, isso afeta 0,7% do traçado nas linhas de dois sentidos, em laços de terminal, e **41% nas de sentido único**, que vão e voltam pela mesma avenida. Ali, escolher só pela distância erra a passagem metade das vezes.

A solução usa continuidade. Cada posição guarda as passagens candidatas: até seis, com erro de até o melhor + 10 m, separadas por mais de 150 m ao longo da rota. Para cada ônibus, em ordem de tempo, escolhe-se a sequência de candidatos mais coerente com o algoritmo de Viterbi, em que cada transição tem um custo:

Transição	Custo
andar para a frente a até 80 km/h	~0
recomeçar a volta, do fim para o início	50
recuar ou teleportar	1.000 + distância
mais de 5 min sem posição	quebra a continuidade

O teste, em 08/10, com 4 circulares e 2 linhas normais, somou 93 mil posições:

Pares consecutivos incoerentes	Só o mais próximo	Com continuidade
Sentido único	20,4%	**4,2%**
Dois sentidos	2,9%	2,9%

7.4 O que sobra e o que foi medido

O que continua incoerente vem do próprio dado e é tratado no capítulo 8. São três fenômenos: a manobra no terminal, em que `d` oscila perto das pontas; o **sentido atrasado**, em que o ônibus já voltou e a API ainda manda o sentido antigo; e o **eco**, em que a API reenvia uma posição antiga com `ta` novo.

O erro lateral cresce com o tempo usando o GTFS de 26/08: o percentil 99 sobe de 0 m no fim de agosto para ~1,4 m em outubro, e a fração acima de 10 m passa de 0,01% para ~0,3%. A SPTrans vai mudando os traçados aos poucos.

As checagens são `rota = limpa` por dia e todo `d_m` entre 0 e o comprimento do traçado.

7.5 Decisões da projeção

Decisão	Motivo
Transformar posição em metro da rota	velocidade e trechos ficam contas de uma dimensão
Plano equirretangular	erro desprezível na escala da cidade e conta rápida
Python com `cogroup` por traçado × dia	lógica testável no PC e grupos pequenos
Candidatos + Viterbi	resolve a ambiguidade usando a sequência do ônibus

8. Silver: deslocamentos

8.1 O par como unidade

Uma posição sozinha não tem velocidade. Velocidade precisa de dois instantes. A `silver.deslocamento` tem uma linha por **par de posições consecutivas do mesmo ônibus no mesmo dia**: de onde foi, para onde foi, em quanto tempo.

A 1 minuto entre posições, um par anda de 200 a 700 m, mais que um trecho entre paradas, que tem ~300 m. Isso define o capítulo 9.

Os pares são formados dentro do dia, por `(p, dt)`. O par que cruza a meia-noite se perde, num horário com poucos ônibus, e cada dia fica independente: dá para reprocessar um dia sozinho.

8.2 Ecos

Antes de formar os pares, saem os ecos: posições com coordenadas idênticas às de 2 ou 3 posições antes, mas diferentes da anterior. A API reenviou uma posição antiga com `ta` novo. Isso acontece em ~1% das posições e não é uma observação. Os ecos entram na conta da checagem, mas não viram par.

8.3 As situações

Todo par fica na tabela com uma `situacao`, e só os `ok` seguem para a velocidade. Cada par recebe a primeira que se aplica:

situacao	Regra	Motivo	% dos pares
`buraco`	mais de 5 min entre as posições	coleta perdida	0,44%
`nova_viagem`	mudou de traçado, ou foi do fim (últimos 300 m) para o início (primeiros 300 m)	uma viagem acabou e outra começou	2,21%
`terminal`	as duas pontas a até 200 m do início ou do fim, e andou menos de 50 m	ônibus esperando ou manobrando	23,58%
`recuo`	andou mais de 30 m para trás	inclui o sentido atrasado	1,71%
`rapido`	mais de 80 km/h	impossível para ônibus urbano	0,32%
`parado_longo`	dentro de uma sequência parada que soma ≥ 20 min	frota estacionada fora do terminal	3,78%
`ok`	o resto	vai para a velocidade	**67,96%**

São **540,4 milhões de pares**, e 367,2 milhões são `ok`. A checagem é `posições = pares + ecos + ônibus`, porque cada ônibus-dia tem uma posição a mais que pares.

Ônibus lento ou parado no meio da rota fica `ok`. Velocidade perto de zero num engarrafamento é o sinal que queremos comparar com e sem chuva. Recuos pequenos, entre −30 e 0 m, são ruído e também ficam `ok`, com distância contada como 0.

8.4 `parado_longo`: a história da madrugada

No dashboard, a velocidade média caía de madrugada (12,5 km/h às 2h), justo no horário em que deveria ser a mais alta. O meio do dia também parecia lento demais.

A investigação, em 13 a 17/10, mostrou que às 2h **53% do tempo** dos pares `ok` era de ônibus parado, enquanto quem andava fazia 27 km/h. De madrugada, 62% do tempo parado estava em paradas de 20 min ou mais, dois terços delas no meio da rota, a ~3 km das pontas. São garagens e pontos de regulagem. O resto ficava a ~400 m das pontas, em áreas de espera além dos 200 m da regra `terminal`.

Excluindo paradas de 20 min ou mais, em 13 a 17/10:

Hora	Antes	Depois
2h	12,5 km/h	22,3 km/h
11h	13,7 km/h	14,9 km/h
18h (pico)	12,1 km/h	12,4 km/h

A espera entre viagens também inflava o tempo do meio do dia, e os picos quase não mudaram.

A regra: um par que seria `ok`, dentro de uma sequência de pares do mesmo ônibus com menos de 10 m de movimento que soma 20 min ou mais, vira `parado_longo`. O limite de 20 min foi escolhido porque um ônibus preso em alagamento pode ficar parado de 10 a 20 min, e esse é o sinal do projeto. Um ônibus em trânsito normal quase nunca fica 20 min sem andar nada. Como a situação fica na tabela, dá para medir a sensibilidade a essa regra, mas esse teste ainda não foi feito (capítulo 20).

8.5 Como a regra foi validada

O notebook tem um modo de teste, com um dia e poucas linhas, que mostra o **diagrama de Marey**: hora no eixo x, metro da rota no eixo y, uma linha por ônibus. Viagens aparecem como diagonais, mais inclinadas quando mais rápidas. Ônibus parado aparece como trecho horizontal. Dois ônibus colados são um comboio. Os pares fora de `ok` aparecem coloridos, o que mostra se cada regra pegou a coisa certa.

Foi assim que o `recuo` foi entendido: apareceu como trajetórias inteiras descendo por ~30 min, que são viagens reais com o sentido atrasado na API. Hoje esses pares ficam fora. Reprojetá-los no traçado do outro sentido é uma melhoria possível.

A velocidade dos pares `ok` dá 14,7 km/h na v1 e 14,6 km/h na v2. Os dois formatos são comparáveis, e dá para usar o período inteiro.

8.6 Decisões dos deslocamentos

Decisão	Motivo
O par de posições é a unidade de observação	velocidade precisa de dois instantes
Classificar cada par com uma `situacao`	dá para mudar regra e medir o efeito
Parado no meio da rota continua `ok`	é o sinal que o projeto quer medir
Limite de 200 m e 50 m para `terminal`	no teste, 91% desses pares tinham menos de 10 m de movimento
20 min em `parado_longo`	separa frota estacionada de ônibus preso no trânsito ou em alagamento
Pares dentro do dia	cada dia pode ser reprocessado sozinho

9. Silver: velocidade por trecho

9.1 O que é um trecho

Um **trecho** vai de uma parada à seguinte. O `06_silver_velocidade_trecho` tem duas partes: primeiro define os trechos, depois calcula a velocidade em cada um.

9.2 Parte A: `gtfs_trechos`

Para ratear pares entre trechos, cada parada precisa estar na mesma régua das posições. As paradas de cada viagem são projetadas no traçado **em ordem**: cada uma tem que cair adiante da anterior.

Essa etapa precisou de três versões, por causa das linhas que vão e voltam pela mesma avenida. A parada do início da ida também fica a poucos metros da volta, na calçada oposta, lá perto do fim da rota.

Versão	Regra	Trechos	Trechos de 0 m	Erro mediano da parada
1ª	menor erro entre as passagens adiante	170.291	23.479	4,8 m
2ª	a passagem boa mais próxima adiante	192.949	821	10,0 m
3ª	menor erro entre as passagens que começam até 1,5 km adiante	193.020	750	4,7 m

Na 1ª versão, a parada pulava para a volta e as seguintes ficavam presas lá: uma linha de 146 paradas ficou com 10 trechos. A 3ª usa o fato de que paradas ficam a ~310 m umas das outras. Cada versão foi testada no PC com traçados sintéticos, e uma checagem falha se os trechos de 0 m passarem de 0,5%. Trechos de ~0 m saem da tabela, que hoje tem 193.304 trechos nas duas versões do GTFS.

9.3 Parte B: o rateio

Como um par anda mais que um trecho, quase nenhum trecho tem uma posição dentro dele. Cada par `ok` então reparte distância e tempo entre os trechos que atravessou, supondo velocidade constante dentro do par:

```
par: metro 12.060 → 12.330 (270 m) em 45 s; parada no metro 12.150

   12.060 ──────┼──────────────── 12.330
       90 m em 15 s    180 m em 30 s
     trecho anterior   trecho seguinte
```

Cada pedaço vai para a **janela de 10 min** do seu instante médio. Em cada trecho × janela:

```
velocidade = soma das distâncias / soma dos tempos
```

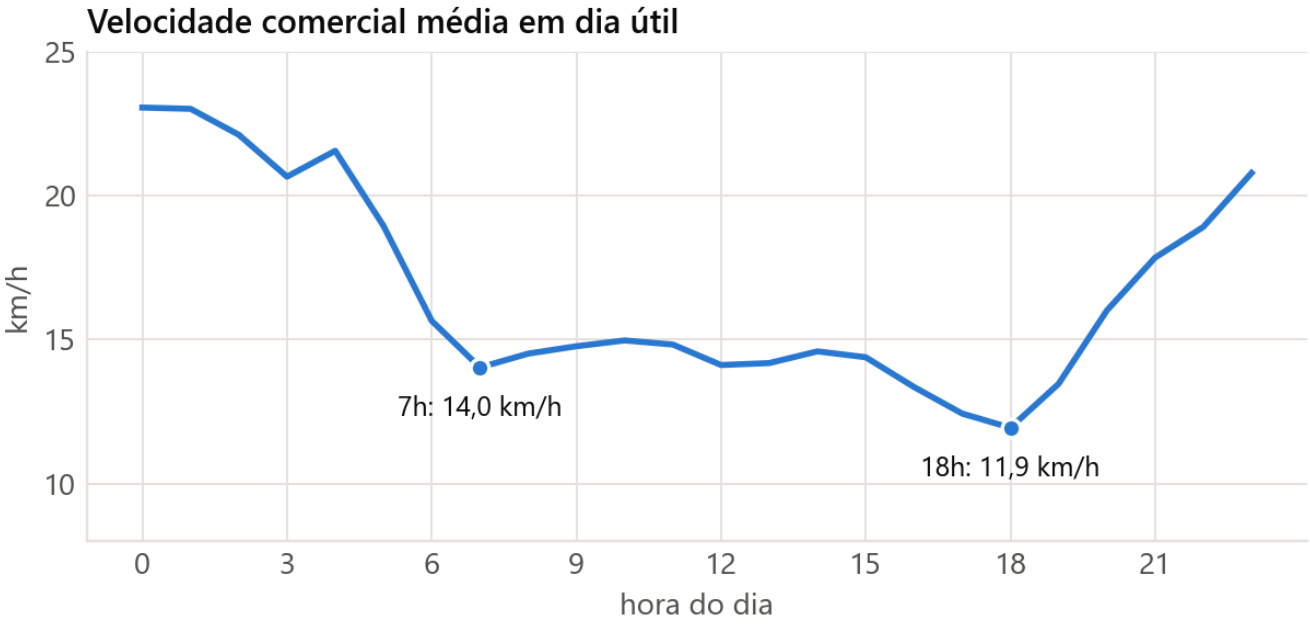
Um par parado conta tempo no trecho onde está, com distância 0. Assim, um par curto e lento pesa menos que um longo, e um ônibus preso acumula tempo no trecho.

A tabela guarda também `n_pares` e `n_onibus`, que dizem quanto dado sustenta cada velocidade. O que o ônibus anda antes da primeira parada e depois da última fica de fora.

9.4 Checagens e números

Nenhuma velocidade passa de 80 km/h, o tempo rateado nunca passa do tempo dos pares e ~99,6% do tempo e 99,8% da distância ficaram dentro dos trechos. O rateio foi testado com cinco pares sintéticos (cruzando parada, parado, recuo pequeno, saindo da última parada, fora do traçado), e esse teste pegou um erro de código antes de rodar na base.

A tabela tem **317,1 milhões de linhas**, 29.965 trechos físicos e 1.309 linhas de ônibus. A velocidade comercial média é **15,5 km/h**: 15,08 em dia útil, 16,55 no sábado, 17,75 no domingo e 18,75 em feriado.



Em dia útil, a velocidade cai no pico da manhã, fica estável no meio do dia e chega ao mínimo às 18h.

9.5 Trecho físico

Um trecho de uma linha é `(traçado, sequência)`. O **trecho físico** é `(parada_de, parada_ate)`, sem olhar a linha. Paradas são cadastradas por lado da rua, então o trecho físico tem sentido. Ele junta todas as linhas que passam ali e multiplica as observações nos lugares com mais ônibus. A gold inteira usa o trecho físico.

Essa definição tem um efeito colateral, que apareceu só no KR3: linhas que pulam paradas geram pares diferentes na mesma rua, e trechos físicos podem se sobrepor (seção 17.6).

9.6 Decisões da velocidade

Decisão	Motivo
Trecho = par de paradas consecutivas	unidade natural da rede, com precedente no Monitor de Ônibus do IEMA
Rateio por sobreposição	os pares são maiores que os trechos
Janela de 10 min	casa com a resolução dos pluviômetros
Soma das distâncias ÷ soma dos tempos	pondera pelo tempo, e ônibus parado pesa
Guardar `n_pares` e `n_onibus`	a gold decide o mínimo de dado
Agregar a gold por trecho físico	mais observações por lugar e unidade natural para a infraestrutura

10. Silver: chuva

10.1 A fonte

A chuva vem do **SIBH** (`sibh.daee.sp.gov.br`), na telemetria, com a granularidade "Coleta", de 10 min. O site exporta CSV de até 10 postos por consulta e bloqueia automação no `robots.txt`, então a extração foi manual: 161 postos do município em blocos, totalizando 18 arquivos, de 01/08 a 25/10, com dado de **141 postos**. As coordenadas vêm de `stations.json`, capturado pelo DevTools do navegador, com ~3.700 postos do estado. Tudo está em `docs/chuva_sibh.md`.

O formato é `Prefixo, Nome, TipoPosto, Data, Valor, Valor2`. `Valor` é o incremento em mm desde a leitura anterior.

O horário é UTC. O Windows registra o horário de salvamento em horário de Brasília. Um arquivo salvo às 18:04 termina em `21:00`, e outro, salvo às 18:55, termina em `21:40`. Se fosse horário de Brasília, os arquivos teriam chuva de 3 horas no futuro. Em UTC, 21:00 são 18:00, a última leitura antes do download. Toda consulta iniciada em 01/08 00:00 também começa às 03:00.

Antes de subir, cada afirmação sobre os dados foi conferida lendo os CSVs. Isso achou 15 valores negativos (manutenção do pluviômetro), uma leitura de 35 mm em 10 min e a identificação correta da rede `3550308xx`, que é do CEMADEN.

10.2 As três redes

Rede	Operador	Postos	Como reporta
`daee`	SAISP, SP Águas, Sabesp, ANA	83	grade fixa de 10 min, com zeros explícitos
`cemaden`	CEMADEN	56	por evento: seco, 1 leitura por hora; chovendo, a cada ~10 min
`inmet`	INMET	2	horária

Essa diferença importa na gold. Na rede CEMADEN, a primeira leitura depois de uma hora seca cobre a hora inteira. Repartir essa chuva pelos slots espalha a chuva até 50 min antes de ela começar.

10.3 O notebook 07

O `07_silver_chuva` grava três tabelas. `bronze.chuva_sibh` tem as leituras como vieram (1.124.746 linhas), e a checagem é que a soma bata com o manifesto. `silver.chuva_10min` coloca tudo numa grade comum de 10 min em UTC (1.718.603 linhas). `silver.postos` tem uma linha por posto, com coordenadas, rede, qualidade e status.

Cada leitura vale para o intervalo desde a leitura anterior do mesmo posto, repartido igualmente entre os slots:

Caso	O que acontece
leitura a 10 min da anterior	1 slot, valor inteiro
posto a 5 min	duas leituras no mesmo slot, somadas
leitura 60 min depois, com 0 mm	6 slots com 0
leitura 60 min depois, com 3 mm	6 slots com 0,5 mm e `f_intervalo_longo`
intervalo maior que 60 min	só o último slot recebe; os anteriores ficam faltantes
leitura negativa	slot nulo, com `f_negativo`
slot sem leitura	nulo, com `f_faltante`

Slot sem leitura é **nulo, nunca zero**: "não sei" e "não choveu" são coisas diferentes. Um slot acima de 30 mm fica com o valor e a marca `f_pico_implausivel`.

A checagem de **conservação** diz que, por posto, a chuva na grade é igual à soma das leituras não negativas: o rateio espalha e não cria chuva. A exceção são dois postos em que uma leitura negativa caiu no mesmo slot de uma positiva.

10.4 Qualidade dos postos

Três medidas foram feitas no período com ônibus, desde 25/08. A `completude` é a fração de slots com valor. A `razao_vizinhos` é o total do posto dividido pela mediana do total dos 5 vizinhos confiáveis mais próximos. A `chuva_1209_mm` é o total em 12/09, dia de chuva forte em toda a cidade: posto que marca 0 está quebrado.

O status é o primeiro que se aplica: `sem_dado`, `quebrado` (razão abaixo de 0,4, ou 0 mm em 12/09), `suspeito` (razão acima de 2,0), `lacunar` (completude abaixo de 90%) ou `ok`.

Rede	ok	lacunar	quebrado
DAEE	71	5	6
CEMADEN	23	5	27
INMET	1	1	0

A tabela soma 139 postos. Os outros 2 não têm leitura desde 25/08 e vão aparecer como `sem_dado` quando o notebook 07 rodar de novo. Isso não afeta a gold, que usa só postos `ok`.

Duas correções saíram desse controle. Na primeira versão, 5 postos normais saíram como suspeitos porque os vizinhos de referência eram postos CEMADEN com leituras zeradas. O cálculo passou a ter duas passadas. Além disso, `1002855` e `1001855` são o mesmo pluviômetro cadastrado duas vezes, marcado em `duplicata_de`.

O padrão usado na gold é `status = 'ok'` e sem duplicata: **94 postos**, dos quais 70 são DAEE.

10.5 Um período incomum

Setembro de 2026 foi o mais chuvoso da série histórica, desde 1943: 253,8 mm nos primeiros 14 dias, contra média de 83,3 mm para o mês inteiro (INMET, Mirante de Santana). A chuva foi frontal e persistente, espalhada pela cidade. Isso ajuda a ter muitos dias de chuva, mas o resultado pode ser diferente para temporais de verão (capítulo 20).

10.6 Decisões da chuva

Decisão	Motivo
Extração manual em blocos	o site bloqueia automação
Grade de 10 min em UTC	base comum para todas as redes
Falta de leitura é nulo	não confunde “sem dado” com “seco”
Marcar com flags e status	a gold escolhe o critério, e dá para testar outro
Comparar com os 5 vizinhos	a chuva variou 2× na cidade, e a comparação local é mais justa
Usar postos `ok` sem duplicata	94 postos cobrem a cidade sem buracos grandes

11. Automação e dashboard

11.1 O job diário

O job `pipeline-onibus` roda todo dia às 10h, com seis tarefas em fila:

```
ingestao_drive → bronze_posicao → silver_limpa → silver_rota → silver_deslocamento → silver_velocidade
```

Os parâmetros do job descem para todas as tarefas: `dias = ontem` e `linhas` vazio, que é o modo de produção. A ingestão tem até 2 novas tentativas, e uma falha manda aviso por e-mail. Recuperar dias atrasados é um "Run now with different parameters": os 13 dias de 12 a 24/10 levaram 18 minutos.

11.2 O que fica fora do job

Rodam à mão os notebooks que dependem de download manual: o 02 (GTFS novo), o 07 (chuva nova), o 11 (GeoSampa novo). Também rodam à mão os da gold, de 08 a 13, porque só mudam quando há chuva nova. O apêndice A traz a ordem.

11.3 Dashboard

O dashboard "Dash Teste" (AI/BI) tem duas abas. A "Página 1" foi feita na interface, com velocidade por hora, chuva × velocidade por dia, mapa do pico da tarde e postos de chuva. A "Versão API" foi gerada por código, com a definição em JSON guardada em `dashboards/`.

A dispersão de chuva × velocidade por dia mostrou que uma média diária da cidade esconde o efeito: mistura tipos de dia, usa a mediana dos postos e dilui uma tempestade de uma hora. Isso reforçou a decisão de medir por trecho e janela de 10 min, na gold.

11.4 Decisões da automação

Decisão	Motivo
Rodar às 10h de São Paulo	o backup da VM já terminou
Aviso de falha por e-mail	uma falha não passa despercebida
Silver no job, gold à mão	a gold depende da chuva, que é baixada à mão
Job criado primeiro pela interface	objetivo de aprendizado do Gabriel; o bundle fica para depois

12. Gold: visão geral

12.1 O que a gold faz

A silver tem as duas metades do problema, separadas: velocidade por trecho a cada 10 min e chuva por posto a cada 10 min. A gold junta as duas e responde aos KRs. Ela foi desenhada depois de uma exploração feita em 25/10 e de uma revisão de literatura, registradas em `docs/gold_desenho.md` e `docs/gold_literatura.md`.

Notebook	O que faz	KR
08	prepara trechos, postos, chuva por posto e eventos	base
09	junta velocidade e chuva e calcula a velocidade normal	base
10	efeito e recuperação na cidade	KR1, KR2
11	infraestrutura por trecho	KR4
12	efeito por trecho, ranking e infraestrutura	KR1, KR3, KR4
13	recuperação por trecho e por grupo	KR2

12.2 O que a exploração mostrou

A exploração usou dia útil, das 6h às 22h, com o posto DAEE confiável mais próximo de cada trecho.

Quanto dado cada trecho tem. Eram 28.970 trechos físicos. Na mediana, um trecho tem velocidade em 75% das janelas de 10 min, mas cada janela tem só 2 passagens de ônibus. Uma janela sozinha é muito ruidosa, e o efeito só pode ser estimado somando muitas janelas.

A chuva é parecida a que distância? O posto confiável mais próximo fica a 1,6 km na mediana e a até 5 km em 98% dos trechos. A correlação da chuva entre pares de postos DAEE cai com a distância:

Distância	Correlação a 10 min	Correlação a 1 h
até 2 km	0,89	0,94
3 a 5 km	0,72	0,88
5 a 8 km	0,61	0,83
8 a 12 km	0,52	0,77
20 a 30 km	0,32	0,64

Teste de antecipação. Antes de a chuva chegar ao posto, a velocidade deveria estar normal. Ela está normal até ~30 min antes, e cai 1 a 2% nos 20 min anteriores, porque a chuva pode chegar ao trecho antes de chegar ao posto. Isso confirma que os relógios de chuva e velocidade estão alinhados: com erro de fuso, a queda apareceria horas antes.

Falta de dado nos postos. A chuva média da cidade é a mesma com posto presente ou ausente, então os postos não caem de forma ligada ao temporal.

Ônibus somem na chuva? Pouco. Com chuva muito forte, 4% menos trechos têm dado. Os piores momentos saem um pouco da amostra, o que deixa o efeito levemente subestimado.

A linha de base varia. Em períodos secos, a segunda-feira é 3–4% mais rápida e a sexta é mais lenta. A velocidade seca também varia de semana para semana, entre 0,985 e 1,015.

Por trecho. Com chuva moderada ou mais forte, um trecho tem ~80 janelas, mas em só ~13 dias. Como janelas do mesmo dia dependem umas das outras, a evidência efetiva é de ~13 dias.

12.3 Comparação com a literatura

A revisão completa está em `docs/gold_literatura.md`. Poucos estudos com GPS de ônibus publicam o efeito em porcentagem.

Fonte	Chuva leve	Moderada	Forte
Tsapakis et al. 2013, Londres, carros	+0,1 a 2,1% no tempo	+1,5 a 3,8%	+4,0 a 6,0%
Zhang et al. 2018, Pequim, veículos com GPS	−3 a −5%	—	−12 a −15% no pico
Lam et al. 2013, Hong Kong	−4,2%	−6,3%	−7,3%
Chaves Maia, Rio, ônibus GPS	—	−1,0%	−7,3%
Geotab 2026, SP, telemetria, não revisado	−3,2% em dias chuvosos	—	até −14,8%
Este projeto (cap. 15)	**−4,7%**	**−6,3%**	**−9,3%** (muito forte: −14,6%)

Os dois estudos mais próximos são a dissertação de Gonçalves (2018, Poli-USP), com dados de março de 2014 e uma estação de chuva, que encontrou queda de ~6% e até −24% com chuva forte no pico de sexta, e o trabalho de Tenório et al. sobre Niterói. Nenhum dos dois faz ranking de trechos. Os diferenciais daqui são o trecho definido pelo traçado, a chuva a 10 min de vários postos e o período mais longo.

12.4 Decisões gerais da gold

Decisão	Motivo
Dia útil é a análise principal	padrão de demanda homogêneo e mais dias
Medir contra o normal do próprio trecho	cada trecho tem sua velocidade; alguns são sempre lentos
Dia como unidade independente na inferência	a mesma frente fria atinge milhares de trechos juntos
Rede DAEE nas variáveis de tempo	o CEMADEN espalha a chuva até 50 min antes
Regra de estabilidade do KR3 definida antes de olhar	evita ajustar o critério ao resultado

13. Gold: a base (notebook 08)

13.1 Trechos

`gold.trecho` tem uma linha por trecho físico, com 29.965 linhas: coordenadas das paradas, comprimento mediano, linhas que passam, horas de ônibus e velocidade média.

Trechos estranhos ficam na tabela com `f_atipico = true`. A regra usa o comprimento e a sinuosidade, que é o comprimento na rota dividido pela distância em linha reta entre as paradas. É atípico quem tem menos de 30 m ou mais de 3 km, ou sinuosidade abaixo de 0,5 ou acima de 3. Há trecho de 32 km com as paradas a 175 m, por exemplo. São 1.154 trechos, 3,9% do total e 2,2% das horas de ônibus, e eles saem das análises por trecho.

13.2 Os postos de cada trecho

Cada trecho recebe até **3 postos DAEE confiáveis a até 5 km** do seu ponto médio, com peso proporcional a $1/d^2$, em que d tem piso de 0,1 km. Se não há DAEE a 5 km, usa o posto confiável mais próximo de outra rede. Acima disso, o trecho fica sem chuva.

Fonte da chuva	Trechos
DAEE	28.623
outra rede	755
sem posto	587

São 77.337 ligações trecho × posto em `gold.trecho_posto`. O corte de 5 km vem da curva de correlação da seção 12.2. A média de 3 postos reduz o ruído de um posto só.

13.3 Chuva por posto

`gold.chuva_posto_10min` tem 1,16 milhão de slots de 94 postos. Para cada slot, olhando para trás:

Coluna	O que é
`mm_h_30`	intensidade nos últimos 30 min, em mm/h
`mm_h_60`	intensidade nos últimos 60 min
`mm_3h`	acumulado nas últimas 3 h
`seco_3h`	nenhuma chuva nas últimas 3 h, com as 18 leituras válidas
`frac_cidade_chuva`	fração dos postos DAEE chovendo naquele slot
`seco_estrito`	`seco_3h` e menos de 25% da cidade chovendo

"Chove" significa pelo menos 0,2 mm no slot, a resolução do pluviômetro de báscula. As intensidades ficam nulas se faltar qualquer leitura na janela: nulo quer dizer "não sei". Do total de slots, 6,6% têm chuva e 74,6% são seco estrito.

O **seco estrito** define o que é normal. Três horas foi escolhido porque a recuperação da cidade leva cerca de 2 h, e usar 3 h ou 6 h dá o mesmo resultado. A condição da cidade existe porque o congestionamento se espalha: com 25% ou mais da cidade chovendo, trechos secos ficam 3–4% mais lentos fora do pico da manhã.

13.4 Eventos de chuva

Um **evento** começa no primeiro slot com chuva e termina no último slot com chuva antes de **60 min secos**. O período seco mínimo muda muito a contagem por posto DAEE: 147 eventos com 30 min, 105 com 60 min e 72 com 120 min. O `gold.evento_chuva` tem 9.445 eventos, com início, fim, duração, total e pico em 30 min (`pico_mm_h_30`). `tempo_confiavel` marca os eventos da rede DAEE.

Cada slot herda o evento mais recente. Daí saem três colunas: `em_evento`, `min_desde_fim`, em que 0 é o slot logo após o fim, e `min_ate_proximo`, usada no teste de antecipação.

13.5 Checagens

Os pesos de cada trecho somam 1, há no máximo 3 postos, todos a até 5 km, `(prefixo, slot_utc)` é único e a chuva por posto é igual à da silver. Todo slot com chuva está dentro de um evento, e eventos do mesmo posto não se sobrepõem.

13.6 Decisões da base

Decisão	Motivo
Até 3 postos com peso $1/d^2$	o mais próximo já representa bem, e a média reduz o ruído
Corte de 5 km	acima disso a correlação cai rápido
Piso de 0,1 km na distância	posto colado no trecho não vira peso infinito
0,2 mm como limiar	é a resolução do pluviômetro
60 min secos entre eventos	meio-termo medido entre eventos picados e eventos longos demais
Seco estrito de 3 h + cidade seca	dá uma linha de base livre do efeito da chuva e do transbordamento
Trechos atípicos marcados	erros de projeção ficam fora do ranking e continuam disponíveis

14. Gold: observações e linha de base (notebook 09)

14.1 A tabela de observações

`gold.obs_trecho_10min` tem uma linha por trecho × janela com ônibus e chuva: **137,5 milhões de linhas**, de 25/08 a 25/10. Ela junta as linhas de cada trecho físico na janela e calcula a chuva do trecho como média ponderada dos postos com leitura naquele slot. `peso_valido` diz quanto do peso estava disponível. O trecho só é seco se **todos** os seus postos estiverem secos.

14.2 Classes de chuva

Cada observação recebe a primeira classe que se aplica. A intensidade é `mm_h_30`, nos últimos 30 min.

Classe	Regra	% das observações
`sem_dado`	menos de metade do peso com leitura	1,67%
`seco`	todos os postos em seco estrito	70,29%
`transbordamento`	postos secos há 3 h, com ≥ 25% da cidade chovendo	0,44%
`pos_chuva`	sem chuva em 30 min, mas choveu em 3 h	12,38%
`traco`	abaixo de 0,4 mm/h	5,09%
`fraca`	de 0,4 a 2,5 mm/h	6,95%
`moderada`	de 2,5 a 10 mm/h	2,71%
`forte`	de 10 a 25 mm/h	0,40%
`muito_forte`	25 mm/h ou mais	0,07%

O limiar de 2,5 mm/h é o da OMM para chuva moderada. `traco` foi criada porque 0,4 mm/h é menos que uma batida do pluviômetro em 30 min: em geral é um posto distante do trecho. `pos_chuva` existe porque horas logo depois da chuva ainda não são normais.

14.3 A velocidade normal

A linha de base responde: a que velocidade esse trecho andaria nesta janela se estivesse seco? Ela tem três partes:

```
velocidade esperada = v_base(trecho, grupo de dia, hora)
                    × fator(grupo de dia, dia da semana, hora)
                    × fator(semana)
```

`v_base` é a soma das distâncias dividida pela soma dos tempos nas janelas `seco` daquele trecho, hora e grupo de dia (`util`, `sabado`, `domingo_feriado`). Exige ao menos 30 janelas secas em dia útil e 15 nos outros grupos. São 1,33 milhão de combinações em `gold.linha_base`.

Os dois fatores são estimados **para a cidade inteira**, nas janelas secas, cada um usando o que sobrou do passo anterior. Assim não é preciso estimar trecho × hora × dia da semana × semana diretamente, o que deixaria células quase vazias.

Dia útil	Seg	Ter	Qua	Qui	Sex
Fator médio	1,034	1,011	0,995	0,995	0,983

O fator de semana vai de 0,987 a 1,013, com as duas últimas semanas um pouco acima de 1.

14.4 A razão

```
distância esperada = tempo × velocidade esperada
razão = distância / distância esperada
```

Se o ônibus passou 60 s no trecho e a velocidade esperada era 5 m/s, ele deveria andar 300 m. Se andou 270 m, a razão é 0,90.

A view `gold.obs_razao` junta as observações com a linha de base na hora da consulta. Para agregar, a regra é **sempre** `sum(dist_m) / sum(dist_esperada_m)`, e nunca a média das razões, porque uma janela com um ônibus não pesa igual a uma com dez. Essa soma pondera pelo tempo dos ônibus: mostra o que o ônibus sente, e ônibus preso pesa mais. Essa diferença volta nos capítulos 17 e 18.

14.5 Checagens

O notebook falha se `(trecho_id, janela_sp)` repetir, se a distância da gold não bater com a da silver, se a razão no seco fugir de 1 (±0,2% no total, ±0,5% por dia da semana e por semana), se menos de 90% do tempo tiver linha de base, ou se o grupo de dia não combinar com o dia da semana. O resultado: 97,8% do tempo com linha de base e razão no seco de 1,0000.

14.6 Dois erros pegos aqui

Janelas duplicadas. Uma janela das 23:50 podia ter pares em duas partições `dt` da silver, porque a partição é o dia da coleta. Agrupar por `dt` duplicava ~10 mil janelas a cada 3 semanas. A checagem de unicidade pegou. O `dt` da gold passou a ser o dia da **janela**.

Tipo de dia trocado. A primeira rodada mostrou 49 “dias úteis” num período com 42. O `tipo_dia` da `velocidade_trecho` é o do primeiro par de cada traçado × dia, que pode ser de antes da meia-noite. Eram 12.554 linhas, ou 0,009%. O `tipo_dia` da gold passou a vir do calendário, pelo dia da janela.

14.7 Decisões das observações

Decisão	Motivo
Linha de base só com janelas secas	horas de chuva não podem definir o normal
Modelo multiplicativo com fatores da cidade	ajusta dia da semana e semana sem esvaziar células
Mínimo de 30 janelas secas	evita velocidade normal mal estimada
View para a razão	evita duplicar 137 milhões de linhas
Classes `traco` e `transbordamento`	mantêm essas janelas fora do seco, com efeito medido à parte
Trecho seco só com todos os postos secos	a chuva em qualquer posto vizinho pode ter chegado ao trecho

15. KR1 e KR2 na cidade (notebook 10)

15.1 Como sai o intervalo de confiança

Janelas do mesmo dia dependem umas das outras. Tratá-las como independentes daria intervalos estreitos demais, porque há 84,7 milhões de janelas, mas só 42 dias úteis. A unidade independente é o **dia**.

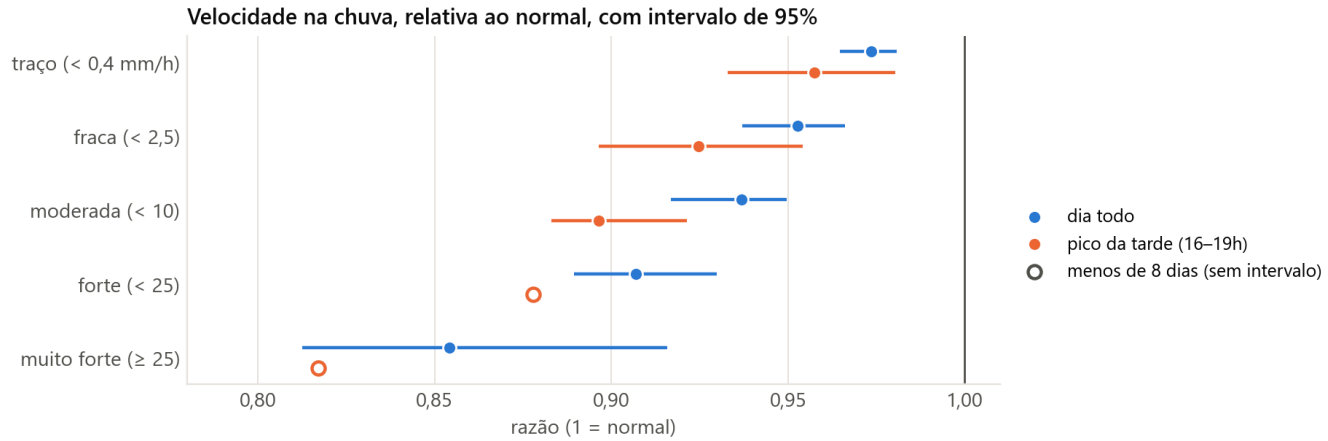
O intervalo vem de um **bootstrap por dias**: sorteamos 42 dias com reposição, recalculamos a razão, repetimos 2.000 vezes e pegamos os percentis 2,5 e 97,5. O cálculo é rápido, porque tudo cabe em tabelas de dia × célula: com `w`, os pesos de cada dia em cada reamostra, `w @ d / w @ e` dá todas as razões de uma vez.

Em cada reamostra, a razão é dividida pela do seco, para a variação entre dias da linha de base entrar no intervalo. Todas as células usam as mesmas reamostras, o que permite comparar uma célula com outra. Células com **menos de 8 dias** são frágeis: mostram a razão, sem intervalo.

15.2 KR1: quanto cai

Razão por classe de chuva e período [IC 95%], em dia útil das 6h às 23h. Entre parênteses, células frágeis:

Classe	Dia todo	Manhã (6–9h)	Meio (10–15h)	Tarde (16–19h)	Noite (20–23h)
pós-chuva	0,993 [0,985–0,999]	0,981 [0,973–0,990]	1,007 [1,000–1,013]	0,986 [0,961–1,005]	0,991 [0,973–1,003]
traço	0,974 [0,965–0,981]	0,974 [0,966–0,983]	0,991 [0,985–0,997]	0,957 [0,933–0,980]	0,969 [0,955–0,983]
fraca	0,953 [0,937–0,966]	0,959 [0,945–0,977]	0,982 [0,972–0,991]	0,925 [0,897–0,954]	0,952 [0,933–0,971]
moderada	0,937 [0,917–0,950]	0,942 [0,929–0,963]	0,963 [0,954–0,983]	0,897 [0,883–0,921]	0,929 [0,855–0,954]
forte	0,907 [0,889–0,930]	0,914 (7 dias)	0,920 [0,908–0,985]	0,878 (6 dias)	0,914 (6 dias)
muito forte	0,854 [0,813–0,916]	sem dado	0,882 (6 dias)	0,817 (3 dias)	0,887 (2 dias)



A queda cresce com a intensidade, e o pico da tarde perde mais em todas as classes.

A queda cresce com a intensidade. Forte perde mais que moderada (0,968 [0,959–0,985]), muito forte perde mais que forte (0,942 [0,888–0,988]), e moderada contra fraca fica no limite (0,983 [0,964–1,001]).

O pico da tarde é o período mais sensível. Comparando tarde com meio do dia: 0,942 [0,910–0,971] na chuva fraca e 0,931 [0,902–0,961] na moderada. Na forte, 0,954 [0,886–1,017], inconclusivo.

A separação entre a coleta a 2 min e a coleta a 1 min dá a mesma direção. No dia todo: fraca 0,942 × 0,965, moderada 0,942 × 0,930. Tirar um dia por vez (jackknife) também não muda o quadro.

15.3 Antecipação

De 60 a 120 min antes de a chuva chegar ao posto, a razão fica entre 0,999 e 1,004. Depois cai: 0,998 entre 30 e 50 min, 0,995 a 20 min e 0,991 a 10 min. O notebook falha se a razão fugir de 1 (±1%) de 60 min para trás.

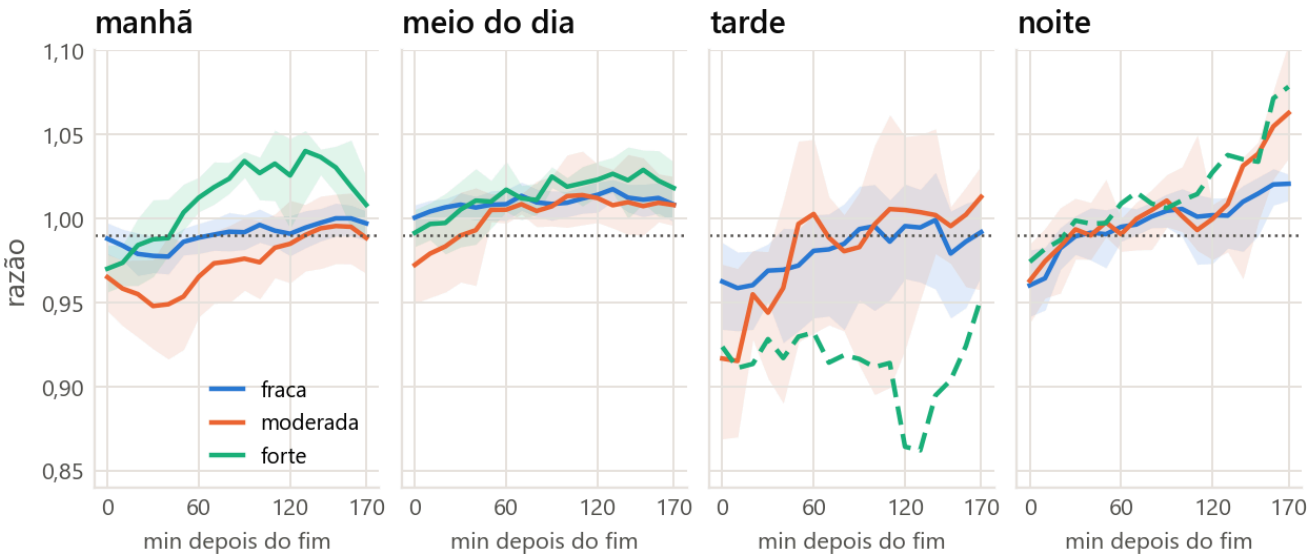
15.4 KR2: recuperação

A curva olha as janelas depois do fim do evento, pelos minutos desde o fim (`tau`). Só entram trechos com postos DAEE, porque as outras redes não marcam bem início e fim. Também saem as janelas a até 40 min da chuva seguinte, por causa da antecipação. São 14% das janelas.

O evento é classificado pelo seu pico: fraco (abaixo de 2,5 mm/h), moderado (até 10) e forte (10 ou mais). O **tempo de recuperação** é o primeiro `tau` em que a razão fica em pelo menos 0,99 por 3 janelas seguidas, buscando até 170 min. Passar de 1 também conta como recuperado.

Tempo em minutos [IC 95%]. “Aberto” quer dizer que mais de 2,5% das reamostras não recuperaram até 170 min:

A chuva acabou	Fraca	Moderada	Forte
de manhã	70 [10–aberto]	130 [70–aberto]	50 [20–50]
no meio do dia	0 [0–0]	40 [0–50]	0 [0–50]
à tarde	120 [40–aberto]	100 [40–aberto]	não recuperou até 170 (6 dias)
à noite	40 [20–70]	30 [10–90]	30 (7 dias)
dia todo	50 [20–80]	90 [50–140]	50 [20–aberto]



Fora dos picos, a velocidade volta logo. Depois de chuva forte à tarde, tracejada por ter só 6 dias, fica abaixo de 0,95 por quase 3 h.

O principal resultado é que **o tempo depende mais da hora em que a chuva acaba do que da intensidade**. Fora dos picos, a velocidade volta em até ~40 min. Nos picos, leva de 1 a 2 h, e chuva forte no fim da tarde pode não se recuperar antes de o pico acabar.

Quando a chuva acaba no meio do dia, a velocidade passa do normal, com razão ~1,01. A hipótese é menos demanda em dia de chuva, ainda sem teste.

A **perda acumulada** é a área entre 1 e a curva nas 2 h depois do fim, em minutos de operação normal perdidos por ônibus. Exemplos: 4,2 min [1,6–6,8] depois de chuva moderada de manhã, 3,6 [−0,9–10,5] à tarde e −1,0 [−1,7 a −0,2] depois de chuva fraca no meio do dia. Essa medida varia menos que o tempo, que depende da primeira vez que uma curva ruidosa cruza um limite.

15.5 Decisões do notebook 10

Decisão	Motivo
Bootstrap de dias inteiros	o dia é a unidade independente
Mesmas reamostras em todas as células	permite comparar células
Menos de 8 dias = frágil	a regra [N] dos KRs
Fora as janelas a ≤ 40 min da próxima chuva	a velocidade cai antes de o posto registrar
Recuperação por período em que a chuva acabou	a curva única escondia a maior diferença
Banda de 0,99 só para baixo	passar do normal também é ter recuperado

16. Infraestrutura (notebook 11)

16.1 Os dados

As camadas vêm do GeoSampa (Fonte: GeoSampa/PMSP, CC BY-SA 4.0), baixadas no PC em 02/11 e guardadas em `infra/versao=2026-11-02/`, com um manifesto de origem e hash. O notebook confere o hash antes de ler.

Arquivo	Conteúdo	Tamanho
Classificação Viária CET	210.754 trechos de via	59,2 MB
Faixas de ônibus	7.378 feições, 779 km	3,0 MB
Corredores de ônibus	45 linhas, 265 km, 40 em operação	0,2 MB
Ocorrências da Defesa Civil	68.946 registros, 2013 a 09/2026, um arquivo por ano	11,3 MB

16.2 Como juntar

Cada trecho vira pontos a cada ~20 m ao longo do seu traçado mais usado, com o rumo local. São 593.936 pontos. Cada ponto procura a linha mais próxima da camada dentro de um raio, com rumo parecido (até 30°, sem olhar o sentido), para não pegar a rua transversal num cruzamento. A fração do trecho é a fração dos pontos.

Os raios foram medidos nos dados:

Camada	Distância mediana ao traçado	Raio	Pontos casados
Classificação viária	0,6 m	15 m	98,6%
Faixas exclusivas	0,8 m	15 m	18,3%
Corredores em operação	7 m	25 m	8,6%

16.3 Atributos de cada trecho

`gold.trecho_infra` tem 29.959 trechos. Seis ficaram de fora por não terem traçado representativo.

Tipo de via. Fração do trecho por classe da CET e classe dominante.

Faixa. `frac_faixa` conta as faixas `EXCLUSIVA` (7.003 das 7.378). O desenho das faixas fica no eixo da via e não indica o sentido: 53% dos pontos ficam no mesmo sentido do traçado, e 47% no oposto. Em via de mão única não há dúvida. Em mão dupla, o trecho pode estar do outro lado da rua, e isso vale para 20% do comprimento com faixa. `frac_faixa_via_dupla` marca essa parte. Muitas faixas só valem no pico (mediana de 6 h por dia útil), então `frac_faixa_longa` conta as de ao menos 10 h.

Corredor. `frac_corredor`, com os corredores em operação.

Alagamento. `dias_alag_100m` conta **dias distintos** com `ALAGAMENTO` ou `INUNDACAO` a até 100 m do trecho, de 2013 a 24/08/2026. Contar dias evita um problema real dos dados: uma coordenada aparece 482 vezes, e 3 dias de 2016 somam 3.115 das 12.625 ocorrências. Um temporal só não é histórico. Só entra o que veio antes de 25/08/2026, para a chuva do período estudado não explicar a si mesma. São 12.494 ocorrências em 1.454 dias. O raio é 100 m porque a ocorrência fica no endereço do chamado. `dias_alag_50m` serve de sensibilidade.

16.4 Validação

As classes vêm da CET, e a velocidade vem dos ônibus. Se a junção estiver certa, a velocidade segue a hierarquia viária:

Classe dominante	Trechos	km	Velocidade média
VTR	23	23	29,5 km/h
Rodovia	123	100	27,2 km/h
Arterial	9.974	4.504	16,2 km/h
Coletora	16.717	5.079	14,5 km/h
Local	1.897	661	13,0 km/h

O notebook falha se essa ordem quebrar. Trechos em corredor andam a 17,5 km/h, em faixa a 15,9 km/h e sem nenhum dos dois a 15,1 km/h. Os trechos com mais dias de alagamento são Prestes Maia/Anhangabaú (73 dias) e o eixo Av. Ribeirão Jacu/Musgo de Flor, na Zona Leste, ambos pontos conhecidos. 38,7% dos trechos têm ao menos um dia de alagamento a 100 m, com mediana 0, percentil 90 igual a 4 e máximo 73.

16.5 Decisões da infraestrutura

Decisão	Motivo
Pontos a cada 20 m, com rumo	vira uma conta simples de fração, e o rumo evita ruas transversais
Raios medidos nos dados	a distância real difere por camada
Dias distintos de alagamento	há blocos de chamados
Só ocorrências antes de 25/08/2026	o histórico não pode conter o período estudado
Marcar faixa em via de mão dupla	a dúvida fica visível e pode ser testada
Agrupar VTR e rodovia como via expressa	juntas têm só 146 trechos
Conferir hash do manifesto	garante que o arquivo é o baixado

17. Efeito por trecho, ranking e infraestrutura (notebook 12)

17.1 A regra [N]

O [N] dos KRs virou uma regra de dado mínimo: chuva moderada ou mais forte em **pelo menos 8 dias e 30 janelas**, com postos DAEE, sem trechos atípicos. São **24.576 trechos**, de 26.235 com alguma chuva moderada ou mais forte (93,7%).

17.2 Estágio 1: o efeito de cada trecho

Um trecho pode parecer pior só por ter pegado chuva forte no pico da tarde. Para evitar isso, o efeito desconta o que a cidade perde em cada combinação de período e classe de chuva, numa conta do mesmo tipo de uma taxa padronizada:

```
e* = e × R(período, classe)     R = razão da cidade naquela célula

theta = log( Σ d / Σ e* )  −  log( Σ d_seco / Σ e_seco )
```

`theta = 0` quer dizer que o trecho perdeu o mesmo que a cidade, e `theta < 0`, que perdeu mais. Para ler na escala de razão, a `razao_padronizada` multiplica `exp(theta)` por 0,931, a razão da cidade nessa chuva.

O erro de `theta` vem da variação **entre dias**. Cada dia empurra a estimativa um pouco (a função de influência), e a soma dos quadrados dá a variância, agrupada por dia. A chuva e o seco do mesmo dia somam antes de elevar ao quadrado, porque vêm do mesmo dia.

O erro típico é 0,042, e quase não cai com mais horas de ônibus (de 0,049 a 0,042 entre os grupos de exposição). Ele vem do dia, com seus acidentes e sua chuva. Com ~13 dias, cada variância é ruidosa, então ela é **moderada**: puxada para a tendência de trechos com exposição parecida, com a fórmula do `limma` (Smyth, 2004). A tendência vale 2,4 graus de liberdade.

17.3 Estágio 2: o encolhimento

Em 24 mil trechos, os extremos são em parte azar. O encolhimento puxa o efeito de cada trecho para o esperado pelas suas características, mais forte quanto maior o erro:

```
theta_i = x_i g + u_i + ruído_i
u_i ~ mistura de normais de média 0 e larguras 0; 0,005; 0,01; ...; 0,64
```

`x_i` tem classe de via, alagamento, faixa, corredor, proximidade de terminal, comprimento, horas de ônibus e distância ao posto. Os coeficientes `g` saem de mínimos quadrados ponderados, e os pesos da mistura saem do algoritmo EM.

A mistura segue a ideia do `ashr` (Stephens, 2017). Uma normal só assume que ninguém foge muito da média, e achatava os extremos: um trecho com −0,53 e erro 0,07 virava −0,13, e o Jaccard do top-10 ficava em 0,18. A mistura permite que poucos trechos sejam muito piores. Os pesos estimados ficaram em 66% na largura 0,04 e 20% em 0,02, com menos de 1% nas larguras de 0,16 e 0,32.

O resultado é a `razao_encolhida`, que ordena o ranking, com intervalo aproximado e `p_queda`, a probabilidade de a razão verdadeira ser menor que 1.

17.4 Resultado do KR1 por trecho

Em **8.700 trechos (35,4%)**, `p_queda` é de ao menos 95%. A razão encolhida vale 0,924, 0,968 e 1,012 nos quantis de 5%, 50% e 95%.

O trecho típico (0,968) perde menos que a cidade (0,931). A razão da cidade soma tempo, e nela trechos cheios e ônibus presos pesam mais. As duas leituras estão certas e respondem a perguntas diferentes: a primeira descreve o trecho típico, e a segunda, o que o ônibus sente.

17.5 KR3: o critério reprovou

O critério de estabilidade foi fixado antes de olhar: cada um dos 10 primeiros no top-20 em ao menos 80% das réplicas, e Jaccard mediano de pelo menos 0,5. Cada réplica sorteia 42 dias e refaz os dois estágios, 500 vezes.

Medida	Critério	Resultado
Jaccard mediano do top-10	≥ 0,5	**0,33**
Dos 10, quantos ficam no top-20 em ≥ 80% das réplicas	10	**3**
Top-10 no top-20 de cada réplica, mediana		7 de 10
Trechos diferentes em algum top-10		268

O motivo é a quantidade de dias. Dividindo os dias em duas metades, a correlação de postos do efeito entre as metades é 0,26. Projetando para todos os dias pela fórmula de Spearman-Brown, a **fiabilidade é 0,42**. Com o dobro de dias de chuva, ficaria perto de 0,59. Esse número é indicativo.

Foram testadas alternativas:

Teste	Resultado
Mistura de normais	Jaccard de 0,18 para 0,33; adotada
Eixos de trechos de 1, 2 e 4 km	fiabilidade 0,46
Comparar só dentro do mesmo dia	fiabilidade 0,43
Estimadores robustos entre dias	fiabilidade de 0,31 a 0,42
Ranking por local, em grade de 200 m a 1 km	Jaccard até 0,43; de 2 a 4 dos 10 estáveis
Incluir chuva fraca	Jaccard 0,33; 2 dos 10 estáveis

Nenhuma passou no critério, e ele continua o mesmo. Uma simulação a partir do modelo foi descartada: ela herdava as caudas do próprio modelo e dava o mesmo resultado para qualquer número de dias.

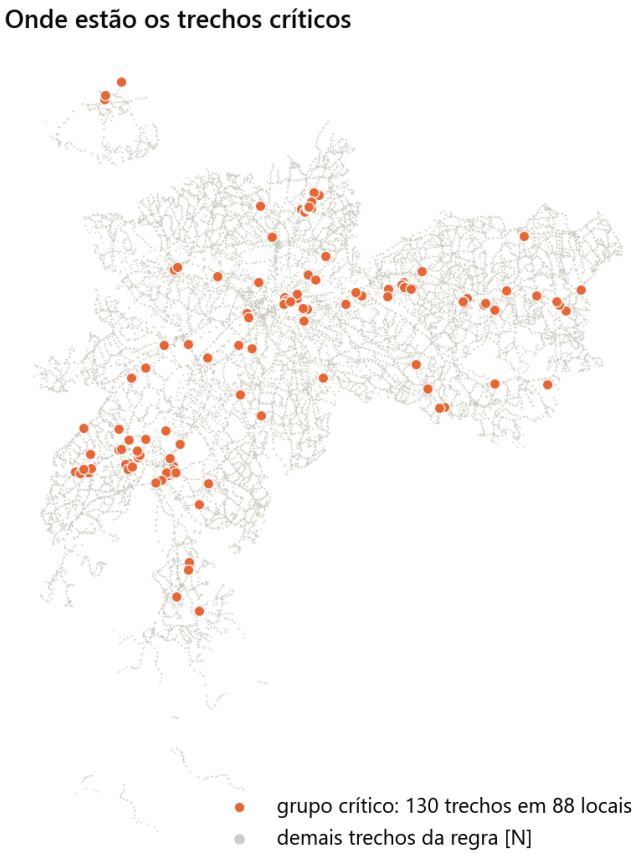
17.6 O que é estável: o grupo crítico

Existe sinal real. Os 1% piores escolhidos numa metade dos dias continuam ~11% abaixo da média na outra metade.

O **grupo crítico** reúne os trechos entre os 5% piores em ao menos 80% das réplicas: **130 trechos em 88 lugares**, 67 km, com razão mediana 0,844. Trechos a até 300 m contam como um lugar, porque trechos físicos se sobrepõem. A R. Maria Eugênia Celso → R. Dr. Campos Moura, por exemplo, aparece com 5 destinos diferentes. Quatro evidências sustentam o grupo:

- **Fora da amostra:** o resultado acima.
- **Placebo:** nas janelas secas dos mesmos dias, o grupo fica normal (−0,01). Efeito e placebo quase não se relacionam (Spearman 0,055). Isso afasta uma obra ou desvio naqueles dias como causa geral.
- **Outra definição:** incluindo a chuva fraca, o ranking tem correlação 0,84 com este, e 7 dos 10 primeiros são os mesmos.
- **Dia a dia:** os líderes perdem de forma repetida. A Av. Pref. Paulo Lauro fica abaixo do esperado em 14 de 15 dias.

No grupo, 58% dos trechos estão em arteriais (35% no geral), 23% têm ao menos 5 dias de alagamento (7,6% no geral) e 15% ficam perto de terminal (5% no geral).



Os trechos críticos se espalham pela cidade, com concentrações na Zona Sul, no centro e na Zona Norte.

Os primeiros lugares, na ordem do efeito encolhido, que não é estável:

Lugar	Razão encolhida	Velocidade média
Estr. de Itapecerica, 861 → 541	0,50	4,8 km/h
Av. Sabin, 415 → 151	0,51	7,2 km/h
R. Maria Eugênia Celso → R. Dr. Campos Moura	0,52 a 0,58	6 a 12 km/h
R. Geraldo Fraga de Oliveira, 426 → 224	0,57	6,1 km/h
R. Getulina → Est. CPTM Guaianases	0,58	12,8 km/h
Av. Mj. Sylvio de Magalhães Padilha	0,61	28,2 km/h
Estr. do Lageado Velho, 1369 → 1501	0,64	12,4 km/h

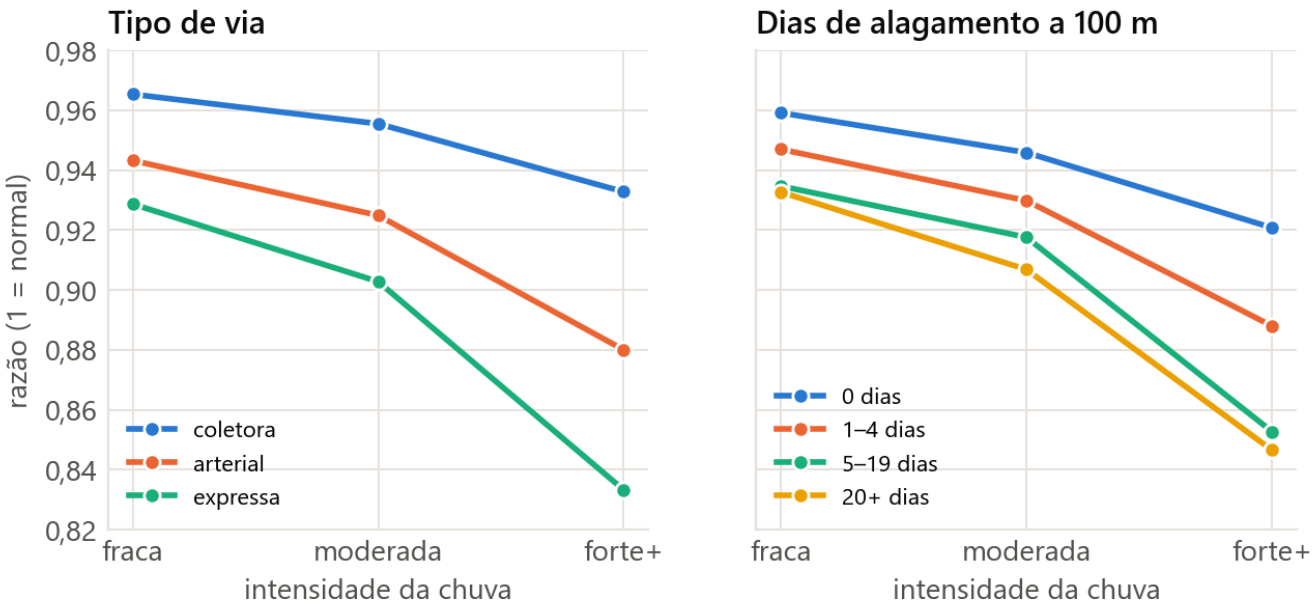
Três cuidados valem para essa lista. A Estr. de Itapecerica ficou bem mais rápida em outubro mesmo no seco (razão seca de 0,8 para 1,6), sinal de uma mudança local a investigar. Vários líderes são gargalos muito lentos, onde a fila amplifica a chuva. Perto de terminal, parte da queda pode ser espera.

17.7 KR4: tipo de via

A primeira leitura soma os trechos por grupo, com intervalo por bootstrap de dias. Ela tem muito mais dado que um trecho só e mostra o que o ônibus sente. Comparada à via coletora, em IC de 95%:

Chuva	Coletora	Arterial	Expressa
fraca	0,965	−2,3% [−3,0 a −1,6]	−3,8% [−5,1 a −2,2]
moderada	0,956	−3,2% [−4,5 a −2,1]	−5,5% [−8,4 a −3,5]
forte+	0,933	**−5,7%** [−7,3 a −3,1]	**−10,7%** [−18,3 a −2,5]

Via local não difere da coletora. A segunda leitura é o modelo do estágio 2, que compara trechos parecidos. Nele, a diferença da arterial é de −0,4% [−1,2 a −0,2] para o trecho típico e de −1,6% [−2,6 a −0,4] ponderando por ônibus. A direção é a mesma. A diferença de tamanho vem de os trechos mais cheios perderem mais: −1,4% por unidade de log das horas de ônibus, no modelo ponderado.



Na soma por grupo, a queda segue a hierarquia viária e aumenta com o histórico de alagamento.

17.8 KR4: histórico de alagamento

Razão por dias de alagamento a 100 m:

Chuva	0 dias	1–4 dias	5–19 dias	20+ dias
fraca	0,959	0,947	0,935	0,933
moderada	0,946	0,930	0,918	0,907
forte+	0,921	0,888	0,853	0,847

Parte disso é tipo de via, porque arteriais alagam mais. Por isso a comparação foi repetida dentro de cada classe (5+ dias contra 0 dias):

Chuva	Em coletora	Em arterial
fraca	−3,9% [−6,8 a −1,5]	−1,7% [−3,2 a −0,5]
moderada	−3,3% [−4,5 a −2,1]	−2,2% [−4,0 a 0,0]
forte+	−4,2% [−7,4 a −1,4]	−6,6% [−12,5 a +0,8]

A associação aparece dentro da classe de via e fica mais clara com histórico frequente. Coletoras com 1–4 dias não diferem das sem histórico. Em arteriais, 1–4 dias já mostram −1,1 a −1,7% nas chuvas fraca e moderada. No modelo com todas as covariáveis ela é pequena: −0,43% por unidade de log dos dias [−0,87 a −0,10], ou ~−0,8% indo de 0 a 5 dias. Ponderando por ônibus, −0,42% [−1,14 a +0,17]. A amostra tem de 13 a 16 dias de chuva forte+ e nenhuma enchente grande, então esse pode ser um limite inferior.

17.9 KR4: faixa, corredor e outros atributos

Faixa e corredor não mostraram proteção detectável: −0,5% [−1,2 a +0,4] e 0,0% [−1,0 a +1,2] no modelo. Somando por grupo, parecem perder mais, mas ficam nas arteriais mais cheias. A literatura espera atenuação. Duas limitações pesam aqui: a geometria não diz o sentido da faixa, e linhas podem usar as pistas laterais de um corredor.

`dist_posto_km` vale +0,13% por km [0,04 a 0,29]: quanto mais longe o posto, menor o efeito medido, como se espera com erro de medida da chuva. `log_comprimento` vale −1,8%: trechos curtos perdem menos. `perto_terminal` vale −1,6% [−3,4 a +1,9], inconclusivo, e muda de sinal ponderando por ônibus.

Além do bootstrap de dias, os coeficientes têm um intervalo por blocos espaciais de ~2 km, porque trechos vizinhos não são independentes. As sensibilidades (alagamento a 50 m, sem terminais, só faixas longas em mão única, com velocidade no modelo) não mudam as conclusões.

Tudo isso é associação: trechos não foram sorteados para ter faixa ou para alagar.

17.10 Decisões do notebook 12

Decisão	Motivo
Chuva moderada ou mais forte no ranking	é onde o efeito é claro, e foi o definido antes
Padronizar por período e classe	compara trechos que pegaram chuvas diferentes
Erro agrupado por dia e variância moderada	o dia é a unidade, e 13 dias dão uma variância ruidosa
Mistura de normais	aceita trechos muito piores que a média
Soma das distâncias como estimador	teve a maior fiabilidade entre os testados
Manter o critério de estabilidade	foi fixado antes de ver o resultado
Grupo crítico como proposta separada	mudar o KR é decisão do Rafael
Duas leituras para o KR4	a soma mostra o ônibus, e o modelo compara trechos parecidos
Placebo como checagem	falha o run se a queda aparecer no seco

18. Recuperação por trecho e por grupo (notebook 13)

18.1 O limite do que dá para medir

Uma janela isolada varia ±23%, porque tem ~3 pares de posições. Com esse ruído, um trecho com queda constante de 5%, que nunca recupera, seria marcado como recuperado na 1ª hora em 30% dos eventos. Com queda de 10%, em 17%. Um "primeiro instante em que voltou ao normal" por trecho × evento seria ruído, e por isso a análise de sobrevivência prevista no desenho (Kaplan-Meier e Cox) foi descartada.

A medida por trecho usa faixas de tempo, e o tempo exato fica para os grupos de trechos.

18.2 Por trecho: faixas de tempo

Junta todas as janelas de cada hora depois do fim, em todos os eventos do trecho com pico de ao menos 2,5 mm/h: 1ª, 2ª e 3ª hora. Cada janela desconta o que a cidade perde naquela faixa de 30 min, período do fim e intensidade. Depois vem o encolhimento, como no capítulo 17, e a probabilidade de a razão verdadeira estar abaixo de 0,99.

Classe	Regra (abaixo: P ≥ 0,8; normal: P ≤ 0,2)	Trechos
até 1 h	normal na 2ª hora	14.619
1 h a 2 h	abaixo na 2ª, normal na 3ª	20
mais de 1 h	abaixo na 2ª, 3ª sem resposta	273
mais de 2 h	abaixo na 2ª e na 3ª	41
indefinido	não dá para dizer	6.160

A regra [N] aqui pede ao menos 8 dias e 30 janelas na 2ª hora: 21.113 trechos. Em **14.953 (70,8%)** dá para dizer a faixa.

`perda_2h_min` é a perda nas 2 h seguintes, com quantis de −3,8, −0,3 e 2,9 min. Negativo quer dizer mais rápido que o normal, então o trecho típico volta logo. Quem perde mais durante a chuva tende a perder depois (Spearman −0,49). As razões estão na mistura de chuva da cidade: depois de chuva no pico, o mesmo trecho demora mais.

18.3 Isso se repete em outros dias?

Classificando numa metade dos dias e medindo na outra:

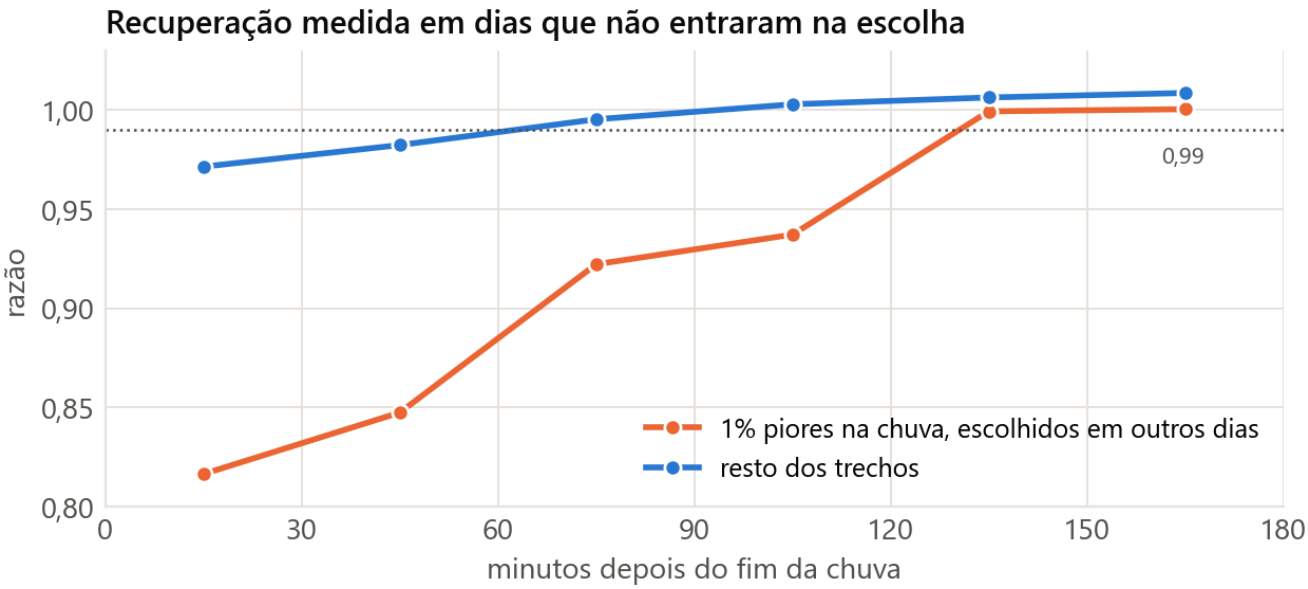
Janela	Fiabilidade	Marcados "abaixo"	Marcados "normal"
1ª hora	0,31	0,966	1,002
2ª hora	0,28	0,987	1,015
3ª hora	0,25	0,992	1,023
2 h seguidas	0,37	0,966	1,006

A classificação prevê outros dias. O notebook falha se essa ordem inverter na 1ª ou na 2ª hora.

18.4 Os piores demoram cerca do dobro

Os 1% piores durante a chuva, escolhidos numa metade dos dias, com a recuperação medida na outra:

Minutos depois do fim	0–30	30–60	60–90	90–120	120–150	150–180
1% piores	0,816	0,847	0,922	0,937	0,999	1,000
resto	0,971	0,982	0,995	1,003	1,006	1,009



Os piores começam bem mais baixo e voltam em cerca de 2 h. O resto volta em cerca de 1 h.

Esse é o número a citar. A curva do grupo crítico em `gold.recuperacao_grupo` fica abaixo de 1 por 3 h, mas ela é contaminada: o grupo foi escolhido nos mesmos dias, e na soma poucos trechos muito ruins pesam mais. O trecho mediano do grupo tem razão 0,98 na 1ª hora e 1,00 na 2ª.

18.5 Por grupo: tempo e perda

Juntando trechos há dado para repetir a regra do capítulo 15, com 1.000 reamostras. Tempo em minutos [IC 95%]; "n/r" é não recuperou até 170 min. A perda é a das 2 h seguintes, comparada à primeira linha de cada bloco:

Grupo	Fora do pico	Pico	Dia todo	Perda (min)	Diferença
Coletora	0 [0–10]	60 [40–aberto]	30 [0–60]	0,4	referência
Arterial	30 [10–50]	n/r	90 [50–aberto]	2,8	+2,4 [0,8–4,5]
Expressa	90 [20–110]	130 [60–aberto]	130 [70–aberto]	6,6	+6,3 [2,0–12,4]
Local	30 [0–aberto]	40 [30–aberto]	30 [0–aberto]	0,8	+0,4 [−1,3–1,6]
0 dias de alagamento	10 [0–20]	130 [50–aberto]	50 [30–aberto]	1,1	referência
1–4 dias	30 [10–50]	n/r	90 [50–aberto]	2,5	+1,4 [0,4–2,5]
5+ dias	50 [20–90]	n/r	150 [50–aberto]	3,7	+2,6 [0,2–6,3]

Grupo	Fora do pico	Pico	Dia todo	Perda (min)	Diferença
Sem faixa nem corredor	10 [0–50]	130 [40–aberto]	50 [30–110]	1,1	referência
Faixa	30 [10–50]	150 [50–aberto]	90 [40–150]	2,1	+1,1 [0,0–3,0]
Corredor	50 [20–90]	n/r	n/r	4,5	+3,5 [0,5–8,0]

A hierarquia viária se repete: fora do pico, coletora volta na hora, arterial em 30 min e via expressa em 90 min. O histórico de alagamento também: 10, 30 e 50 min. No pico, quase nada se resolve em 3 h, e os intervalos ficam abertos: o pico termina antes de a fila dissipar. Por isso, no pico, os grupos se comparam melhor pela perda. O corredor demora mais, mas fica nas arteriais mais cheias, e esta tabela não controla por via.

18.6 Decisões do notebook 13

Decisão	Motivo
Sem sobrevivência por trecho × evento	o ruído de ±23% por janela dominaria o resultado
Faixas de 1 hora por trecho	juntam janelas suficientes
Limites de P ≥ 0,8 e P ≤ 0,2	a mesma exigência de 80% do KR3, validada em outros dias
Citar os piores escolhidos em dias separados	evita contaminação pelos mesmos dias
Tempo exato só por grupo	é onde há dado
Dividir em pico e fora do pico	a hora do fim pesa mais que os outros fatores

19. Os KRs: como alcançamos e em que pé estamos

19.1 Quadro geral

KR	Situação	Resultado em uma linha	Nota sugerida
KR1	pronto	queda de −4,7% a −14,6% na cidade; 24.576 trechos medidos	1,0
KR2	pronto, com adaptação	na cidade e por grupo, tempo em minutos; por trecho, faixa de tempo em 14.953 trechos	0,8
KR3	parcial	top-10 exato reprovado; grupo estável de 130 trechos em 88 lugares	0,5
KR4	pronto	via arterial e expressa perdem mais; alagamento frequente pesa 2–4%; faixa e corredor sem proteção detectável	1,0
KR5	não começou	aspiracional	0,0

As notas são uma sugestão para a conversa com o Rafael, no formato de 0 a 1 dos OKRs.

19.2 KR1: redução da velocidade durante a chuva

Enunciado. Quantificar a redução da velocidade durante a chuva em pelo menos [N] trechos.

[N]. A regra de dado mínimo: chuva moderada ou mais forte em ao menos 8 dias e 30 janelas. São 24.576 trechos, 93,7% dos que tiveram essa chuva.

Como foi medido. A velocidade em cada trecho × janela é comparada com a velocidade normal daquele trecho, hora, dia da semana e semana, estimada nos períodos secos (capítulo 14). O intervalo vem do bootstrap de dias (capítulo 15). Por trecho, o efeito é padronizado por período e intensidade e passa por encolhimento (capítulo 17).

Resultado na cidade, em dia útil:

Chuva	Queda no dia todo	Queda no pico da tarde
traço	−2,6% [−3,5 a −1,9]	−4,3% [−6,7 a −2,0]
fraca	−4,7% [−6,3 a −3,4]	−7,5% [−10,3 a −4,6]
moderada	−6,3% [−8,3 a −5,0]	−10,3% [−11,7 a −7,9]
forte	−9,3% [−11,1 a −7,0]	−12,2% (6 dias)
muito forte	−14,6% [−18,7 a −8,4]	−18,3% (3 dias)

Resultado por trecho. Em 8.700 trechos (35,4%), a probabilidade de queda real é de ao menos 95%. O trecho típico tem razão 0,968.

Tabelas. `gold.efeito_cidade` e `gold.efeito_trecho`.

19.3 KR2: tempo de recuperação

Enunciado. Quantificar o tempo de recuperação da velocidade após a chuva em pelo menos [N] trechos.

[N]. Ao menos 8 dias e 30 janelas na 2ª hora depois do fim: 21.113 trechos. Em 14.953 deles dá para dizer a faixa de tempo.

Como foi medido. Na cidade e por grupo, o tempo é o primeiro momento em que a razão fica em ao menos 0,99 por 30 min (capítulos 15 e 18). Por trecho, a medida usa as faixas da 1ª, 2ª e 3ª hora, validadas em outros dias (capítulo 18).

Resultado.

- Na cidade, fora dos picos, a velocidade volta em até ~40 min. Nos picos, leva de 1 a 2 h.
- Por trecho, 14.619 voltam em até 1 h e 334 levam mais de 1 h, na mistura de chuva da cidade.
- Os 1% piores voltam em ~2 h, e o resto em ~1 h, medidos em dias separados.
- Fora do pico, coletora volta na hora, arterial em 30 min e via expressa em 90 min. Sem histórico de alagamento, 10 min; com 5+ dias, 50 min.

Adaptação. O KR pede um tempo por trecho. O ruído de ±23% por janela não permite um número exato em cada trecho, então o resultado por trecho é uma faixa. A análise de sobrevivência do desenho original foi descartada pelo mesmo motivo. Essa adaptação precisa do aceite do Rafael.

Tabelas. `gold.tempo_recuperacao`, `gold.recuperacao_cidade`, `gold.recuperacao_trecho`, `gold.tempo_recuperacao_grupo` e `gold.validacao_recuperacao`.

19.4 KR3: os 10 trechos mais afetados

Enunciado. Identificar os 10 trechos mais afetados, com ranking estatisticamente estável.

Como foi medido. Efeito padronizado, encolhimento com mistura de normais e 500 reamostras de dias refazendo tudo (capítulo 17).

Resultado. O critério de estabilidade fixado antes de olhar reprovou: Jaccard de 0,33 contra o mínimo de 0,5, e 3 dos 10 primeiros estáveis. Nenhuma alternativa testada passou, em nenhuma unidade.

O que temos é um **grupo crítico** de 130 trechos em 88 lugares, entre os 5% piores em ao menos 80% das réplicas. Ele foi validado fora da amostra, por placebo e por uma definição alternativa do efeito.

O que falta. A proposta é reformular o KR para "grupo crítico estável". Mais dias de chuva devem melhorar a estabilidade: a fiabilidade tende a ir de 0,42 para ~0,59 com o dobro de dias.

Tabelas. `gold.efeito_trecho` (colunas `rank`, `freq_*`, `grupo_critico`, `local_critico`) e `gold.estabilidade_ranking`.

19.5 KR4: infraestrutura

Enunciado. Avaliar a associação entre degradação e dois atributos de infraestrutura: tipo de via e histórico de alagamento.

Como foi medido. Os atributos vêm do GeoSampa (capítulo 16). A associação tem duas leituras: a soma por grupo, com bootstrap de dias, e o modelo do estágio 2, com bootstrap de dias e por blocos espaciais (capítulo 17).

Resultado.

- **Tipo de via.** Em chuva forte+, arterial perde 5,7% a mais que coletora, e via expressa 10,7%. Comparando trechos parecidos, a diferença da arterial fica entre 0,4 e 1,6%.
- **Alagamento.** Trechos com ao menos 5 dias de histórico perdem 2 a 4% a mais, dentro da mesma classe de via, e recuperam mais devagar. No modelo completo o efeito é pequeno, ~0,8% de 0 a 5 dias.
- **Faixa e corredor.** Sem proteção detectável.

Ressalva. É associação. Os dois atributos do KR foram avaliados; faixa e corredor são extras.

Tabelas. `gold.trecho_infra`, `gold.efeito_infra`, `gold.efeito_grupo`.

19.6 KR5: previsão

Enunciado. Prever a degradação dos trechos na hora seguinte a partir da chuva observada.

Estado. Não começou. A base está pronta: chuva, razão e infraestrutura por trecho × janela.

O plano do desenho. O alvo é a razão de 10 a 60 min à frente. Os atributos são a chuva com defasagens, a chuva nos postos vizinhos, a razão atual do trecho e dos vizinhos, a hora, o tipo de dia e a infraestrutura. Os modelos de referência são persistência e perfil histórico, seguidos de regressão ridge e LightGBM. A avaliação usa blocos de dias inteiros em ordem temporal, com métricas separadas para seco, chuva e pós-chuva.

20. Limitações

20.1 O período

Poucos dias. São 42 dias úteis. A chuva forte aparece em 17 dias e a muito forte em 9. Por período, várias células têm menos de 8 dias e ficam sem intervalo.

Um período incomum. Setembro de 2026 foi o mais chuvoso da série, com chuva frontal e espalhada. Temporais de verão são mais localizados e podem ter efeito diferente, inclusive na correlação entre postos.

Sem enchente grande. O KR4 mede a associação com histórico de alagamento num período sem um evento extremo. O efeito em dia de enchente pode ser bem maior.

20.2 A medição

Erro de medida da chuva. O posto fica a 1,6 km do trecho na mediana, e a velocidade cai antes de o posto registrar. Esse erro puxa o efeito para zero. O coeficiente de `dist_posto_km` confirma: quanto mais longe o posto, menor o efeito. Os efeitos devem ser lidos como limites inferiores.

Ônibus somem. Com chuva muito forte, 4% menos trechos têm dado. Os piores momentos saem um pouco da amostra.

`parado_longo`**.** A regra pode remover ônibus presos em alagamento por mais de 20 min.

Velocidade comercial. Ela mistura trânsito e embarque. Chuva piora os dois, e os dados não separam um do outro.

Duas cadências de coleta. Até 20/09 a coleta era a cada 2 min. A velocidade média é a mesma nos dois períodos, mas o período a 1 min fica ~1% acima na velocidade seca. Os dados não dizem se isso é real ou efeito da cadência. Os recortes do notebook 10 mostram a mesma direção nos dois.

GTFS. Só há duas versões, e a segunda só vale a partir de 12/10. Depois disso, o erro lateral volta a crescer.

20.3 A interpretação

Associação. Trechos não foram sorteados para alagar ou ter faixa. Arterial, faixa, corredor e alagamento vêm juntos, e o modelo controla só o que está nele.

Trecho típico e ônibus. As duas leituras dão tamanhos diferentes, e isso deve aparecer sempre que um número for citado.

Terminais. Parte da queda perto de terminal pode ser espera.

Mudanças locais. A linha de base usa fatores da cidade para semana. Uma mudança local, como a da Estr. de Itapecerica, não é corrigida. O placebo pega casos que afetam os dias de chuva, mas não todos.

20.4 O que foi planejado e ainda não foi feito

Item	Onde estava previsto	O que responderia
Rodar KR1 e KR3 com e sem `parado_longo`	seção 8.4	se a regra esconde ônibus presos
Modelo com efeitos fixos: efeito total × efeito local	desenho, 2.5	quanto do efeito é sistêmico
Defasagens distribuídas e curva contínua da chuva	desenho, 2.5	independência dos cortes de classe
Regressão quantílica	desenho, 2.5	efeito nos piores casos
Teto de distância do posto (2, 3 e 5 km)	desenho, 2.9	tamanho do erro de medida
Incluir postos `lacunar`	relatório de 25/10	sensibilidade ao critério de posto
Número de passagens como desfecho	desenho, 2.9	se ônibus somem nos piores momentos
Excluir eleições (04/10, 25/10) e dias de rodízio suspenso	desenho, 2.9	efeito do calendário
Validar com KMZ e lentidão CET	seção 2.5	confirmação por fonte externa
Recuperar pares de `recuo`	seção 8.5	mais 1,7% de pares
Headway como medida secundária	seção 1.1	separar via travada de operação irregular

21. Próximos passos

21.1 Decisões para o Rafael

1. **KR3:** trocar “top-10 com ranking estável” por “grupo crítico estável”. Recomendação: sim, com o top-10 citado como indicativo.
2. **KR2:** aceitar faixas de tempo por trecho, com o tempo exato por grupo. Recomendação: sim.
3. **Mais chuva:** rodar tudo de novo com um novo download. Recomendação: sim, perto do fim do projeto.
4. **[N]:** confirmar a regra de 8 dias e 30 janelas.
5. **Nova data de entrega.**
6. **`parado_longo`:** validar o limite de 20 min.
7. **Plano do Databricks:** manter Enterprise ou trocar.

21.2 Novo download da chuva

A chuva está até 25/10, porque foi até lá que o download foi feito. O job atualiza os ônibus todo dia, mas a chuva depende de download manual, pois o site bloqueia automação. Baixar agora acrescentaria poucos dias. Como o ganho vem de ter mais dias de chuva moderada ou forte, o melhor é baixar perto do fim, com tempo para reprocessar. Vale confirmar antes se o SIBH mantém o histórico de 10 min desde 01/08, consultando um posto só. Se o site guardar só um período recente, o download precisa acontecer antes de perder o trecho que falta.

21.3 Tarefas técnicas

Tarefa	Situação
KR5	a começar, se o tempo permitir
Testes da seção 20.4	priorizar `parado_longo` e o teto de distância do posto
Baixar GTFS novo	recomendado, porque o erro lateral cresce
Rodar o 07 de novo	entra o status `sem_dado`
Rodar o 09 de novo	a correção da coluna `razao` entra na view
Bundle do job	backlog
README escrito pelo Gabriel	backlog
KMZ e CET no Databricks	backlog
Pedido LAI à CET (histórico de lentidão)	texto pronto no `CLAUDE.md`
S3 próprio	backlog, a decidir depois da duração do plano
Saldo da DigitalOcean	conferir

Apêndice A. Como rodar tudo de novo

Todo dia. O job `pipeline-onibus` roda sozinho às 10h. Dias atrasados: “Run now with different parameters”, com a lista em `dias`.

Situação	O que fazer
Chuva nova	baixar do SIBH, subir para `chuva/sibh/download=AAAA-MM-DD/` com o manifesto, atualizar `PASTA` no notebook 07 e rodar 07, 08, 09, 10, 12 e 13
GTFS novo	extrair em `gtfs/versao=AAAA-MM-DD/` e rodar o 02; os dias seguintes passam a usar a versão nova
GeoSampa novo	subir em `infra/versao=AAAA-MM-DD/`, mudar `VERSAO` no 11 e rodar 11, 12 e 13
Mudança numa regra da silver	rodar o notebook da regra e os seguintes com `dias` vazio, depois a gold

A ordem da gold importa: 08, 09, 10, 11, 12, 13. O 11 precisa do 08. O 12 precisa do 09 e do 11. O 13 precisa do 10, para uma checagem, e do 12, por causa do grupo crítico.

Os testes ficam em `analises/gold_exploracao/`: `testa_08.py` a `testa_13.py` rodam a lógica dos notebooks sem gravar nada. `figuras_projeto.py` gera as figuras deste documento.

Apêndice B. As tabelas

Tabela	Uma linha é	Linhas
`bronze.posicao`	um ônibus num ciclo	556,2 M
`bronze.chuva_sibh`	uma leitura de posto	1,12 M
`silver.gtfs_*`	ver seção 5.1	
`silver.gtfs_trechos`	um trecho de um traçado	193.304
`silver.posicao_limpa`	uma posição válida	548,7 M
`silver.quarentena_posicao`	uma posição descartada	7,5 M
`silver.posicao_rota`	uma posição na régua	548,7 M
`silver.deslocamento`	um par de posições	540,4 M
`silver.velocidade_trecho`	trecho de linha × janela	317,1 M
`silver.chuva_10min`	posto × slot	1,72 M
`silver.postos`	um posto	139
`gold.trecho`	um trecho físico	29.965
`gold.trecho_posto`	trecho × posto	77.337
`gold.chuva_posto_10min`	posto × slot	1,16 M
`gold.evento_chuva`	um evento	9.445
`gold.obs_trecho_10min`	trecho físico × janela	137,5 M
`gold.linha_base`	trecho × grupo de dia × hora	1,33 M
`gold.ajuste_dia_hora`	grupo × dia da semana × hora	
`gold.ajuste_semana`	uma semana	
`gold.obs_razao` (view)	trecho físico × janela	
`gold.efeito_cidade`	recorte × período × classe	
`gold.recuperacao_cidade`	período do fim × classe × minutos	
`gold.tempo_recuperacao`	período do fim × classe	
`gold.trecho_infra`	um trecho físico	29.959
`gold.efeito_trecho`	um trecho na regra [N]	24.576
`gold.estabilidade_ranking`	uma métrica	
`gold.efeito_infra`	modelo × termo	60
`gold.efeito_grupo`	grupo × chuva	54
`gold.recuperacao_trecho`	um trecho na regra [N]	21.113
`gold.recuperacao_grupo`	grupo × período × minutos	648
`gold.tempo_recuperacao_grupo`	grupo × período	36

Tabela	Uma linha é	Linhas
`gold.validacao_recuperacao`	uma métrica	32

Apêndice C. Glossário

Bootstrap por dias. Sorteia dias inteiros com reposição, refaz a conta e usa a variação entre as repetições para medir a incerteza.

Censura. Situação em que o evento não foi observado até o fim da medição. Aqui, a reamostra que não recupera até 170 min.

Delta. Formato de tabela usado no Databricks, sobre arquivos Parquet, com histórico e transações.

Encolhimento. Puxar uma estimativa ruidosa para um valor esperado, mais forte quanto maior o erro.

Evento de chuva. Sequência de chuva num posto, separada da seguinte por ao menos 60 min secos.

Fiabilidade. O quanto uma medida se repete. Aqui, a correlação entre metades dos dias, projetada para todos os dias pela fórmula de Spearman-Brown.

GTFS. Formato padrão de dados de transporte público.

Idempotência. Rodar duas vezes dá o mesmo resultado.

Janela. Intervalo de 10 min da velocidade. Na chuva, o mesmo intervalo se chama slot.

Jaccard. Tamanho da interseção dividido pelo tamanho da união de dois conjuntos. Vale 1 se forem iguais.

Jackknife. Refaz a conta tirando um dia por vez.

Linha de base. A velocidade normal esperada para o trecho, naquele horário.

Medalhão. Organização dos dados em bronze, silver e gold.

Mistura de normais. Distribuição formada por várias normais de larguras diferentes, com pesos.

Placebo. Teste que aplica a medida onde o efeito não deveria aparecer. Aqui, as janelas secas dos dias de chuva.

Razão. Distância percorrida dividida pela distância esperada. 1 é o normal.

Regra [N]. Mínimo de dado para um trecho entrar num resultado.

Serverless. Processamento sem cluster para administrar.

Spearman. Correlação calculada sobre os postos, a ordem dos valores.

Traçado (shape). A linha geográfica que uma linha de ônibus percorre num sentido.

Trecho físico. Par de paradas consecutivas, juntando todas as linhas que passam ali.

Unity Catalog. Camada do Databricks que organiza catálogos, schemas, tabelas e volumes.

UTC. Horário universal. São Paulo está em UTC−3.

Velocidade comercial. Distância dividida pelo tempo total, incluindo paradas em ponto e semáforo.

Viterbi. Algoritmo que acha a sequência de escolhas de menor custo total.

Volume. Pasta de arquivos gerenciada pelo catálogo.

Apêndice D. Problemas encontrados e como foram resolvidos

Problema	Como apareceu	Solução
Afirmação errada num relatório antigo: "159 erros absorvidos pelo retry"	auditoria do dado bruto	eram 163 respostas `null` que o retry não pegava; coletor corrigido
Alerta de disco nunca funcionou	`alertas.log` não existia	`%` sem escape no crontab truncava o comando
Listagem do Drive incompleta	1.392 de 1.439 arquivos	conferência contra a auditoria e nova tentativa com espera
Paradas pulando para a volta	23.479 trechos de 0 m	3ª versão da projeção, limitando o salto a 1,5 km
Queda de velocidade na madrugada	gráfico do dashboard	investigação e regra `parado_longo`
Horário da chuva	contradição com o site	prova pelos horários dos arquivos: é UTC
Postos normais marcados como suspeitos	vizinhos quebrados	controle em duas passadas
Mesmo pluviômetro duas vezes	dois postos no mesmo ponto	coluna `duplicata_de`
Janelas duplicadas	checagem de unicidade	`dt` da gold pelo dia da janela
49 "dias úteis"	leitura do relatório do 09	`tipo_dia` da gold pelo calendário
Divisão por zero na coluna `razao`	consulta em `obs_razao`	`try_divide` no 09; 1.659 linhas
Horas de faixa negativas	teste do 11	leitura de `22-00h` corrigida
Blocos de alagamento	3.361 registros numa subprefeitura em 2016	contar dias distintos
Extremos achatados	trecho com −0,53 virando −0,13	mistura de normais
Simulação de dias necessários	mesmo resultado para qualquer número de dias	descartada
Curva do grupo crítico lenta demais	61 trechos do grupo classificados como `ate_1h`	teste em dias separados